

Анализ кандидатов

1. Llama (Meta)

- **Сильные стороны:** Огромное сообщество, множество инструментов (transformers, vLLM, llama.cpp), хорошо документированная архитектура.
- **Слабые стороны:** Веса распространяются по некоммерческой лицензии, процесс обучения документирован частично, нет полной открытости данных и кода обучения.
- **Ограничения:** Нет официального фреймворка для исследований внимания, модификации компонентов сложны из-за монолитной архитектуры.
- **Риски:** Зависимость от политики Meta, нельзя модифицировать для коммерческих целей.
- **Оценка:** Хороший инструмент, но плохой эталон для инженерных экспериментов.

2. OLMo (AI2)

- **Сильные стороны:** Полностью открытый стек — веса, код обучения, данные (Dolma), токенизатор, документация процесса обучения, механизм внимания (с поддержкой альтернатив). Есть готовые хуки для интроспекции внимания.
- **Слабые стороны:** Меньше сообщество, меньше готовых инструментов, чем у Llama.
- **Ограничения:** Только несколько размеров (1B, 7B) — нет 70B+.
- **Риски:** Меньше сторонних доработок, может потребоваться самостоятельная реализация некоторых инструментов.
- **Оценка:** Идеальный стенд для инженерных модификаций.

3. Mistral

- **Сильные стороны:** Отличная производительность, хорошая документация, эффективный токенизатор, поддерживает sliding window attention (документирован).
- **Слабые стороны:** Веса открыты, но код обучения и данные — нет. Токенизатор документирован, но без данных обучения.
- **Ограничения:** Архитектура известна, но неполная спецификация обучения.
- **Риски:** Нельзя воспроизвести обучение, модификации ограничены архитектурой.
- **Оценка:** Хорошая модель, но не подходит для глубокого инженерного анализа.

4. Qwen (Alibaba)

- **Сильные стороны:** Высокая производительность, поддержка длинных контекстов, активное сообщество, разнообразие размеров.
- **Слабые стороны:** Архитектура описана, но не полностью. Данные и код обучения закрыты. Лицензия ограничивает коммерческое использование.
- **Ограничения:** Требуется лицензионное соглашение. Токенизатор документирован, но неполно.
- **Риски:** Зависимость от Alibaba, политика может измениться.
- **Оценка:** Интересная модель, но не пригодна в качестве инженерного эталона из-за закрытости обучения.

5. Gemma (Google)

- **Сильные стороны:** Хорошая документация, поддержка от Google, понятная архитектура, веса открыты.

- **Слабые стороны:** Данные обучения и код — закрыты. Лицензия ограничивает использование.
 - **Ограничения:** Только небольшой размер (2B/7B), токенизатор документирован, но без данных.
 - **Риски:** Зависимость от Google, закрытость обучения.
 - **Оценка:** Качественная модель, но не подходит как лабораторный стенд.
6. Falcon (TII)
- **Сильные стороны:** Полностью открытый стек, включая веса и данные обучения (RefinedWeb).
 - **Слабые стороны:** Меньше сообщества, меньший выбор размеров (7B, 40B — 40B сложно локально).
 - **Ограничения:** 40B требует много ресурсов, 7B — ограничена.
 - **Риски:** Меньше активного развития, чем у OLMo.
 - **Оценка:** Хороший вариант, но уступает OLMo в полноте стека.
7. Другие: Pythia, GPT-NeoX
- **Pythia (EleutherAI):** Специально создана для исследования обучения. Отличный выбор для анализа поведения моделей, но меньше фокус на модификацию архитектуры.
 - **GPT-NeoX (EleutherAI):** Полностью открытый код обучения, но веса и данные закрыты (только код).

Сравнительная таблица

Критерий	Llama	OLMo	Mistral	Qwen	Gemma	Falcon
Открытость архитектуры	Частично	Полная	Частично	Частично	Частично	Полная
Доступность весов	Да (ограниченно)	Да (полностью)	Да	Да	Да	Да
Документация обучения	Частично	Полная	Нет	Нет	Нет	Полная
Документация токенизатора	Да	Полная	Да	Частично	Да	Да
Механизм внимания	Документирован	Полностью документирован	Документирован	Частично	Документирован	Документирован
Локальный запуск	Да	Да	Да	Да	Да	Да (7B)
Модификация компонентов	Сложно	Легко	Сложно	Сложно	Сложно	Сложно
Отключение/замена	Сложно	Легко	Сложно	Сложно	Сложно	Сложно

Критерий	Llama	OLMo	Mistral	Qwen	Gemma	Falcon
механизмов						
Инструменты исследования	Есть (частично)	Есть (специальные хуки)	Нет	Нет	Нет	Нет
Воспроизводимость	Нет	Да	Нет	Нет	Нет	Да
Сообщество	Огромное	Растет	Большое	Большое	Среднее	Среднее
Долговременная поддержка	Meta	AI2 (институт)	Mistral AI	Alibaba	Google	TII

Итоговый анализ

1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?
OLMo от AI2.

2. Почему именно она?

Потому что она единственная из списка предоставляет полностью открытый стек:

- Веса — без ограничений.
- Код обучения — полностью открыт.
- Данные (Dolma) — открыты и документированы.
- Токенизатор — полная спецификация.
- Механизм внимания — документирован и поддерживает модификации.
- Инструменты — есть готовые хуки для исследования внутренних механизмов.

Это делает её идеальным лабораторным объектом, где можно модифицировать внимание, отключать слои, менять токенизатор и знать, как это работает на всех уровнях.

3. Какая модель занимает второе место?

Falcon. Она также предоставляет полностью открытый стек (веса, код обучения, данные RefinedWeb), что делает её воспроизводимой. Однако у неё меньше выбор размеров, а 40B модель сложно запустить локально на одном GPU. OLMo выигрывает за счёт лучшей адаптации к экспериментам.

4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?

- Возможность точного воспроизведения с нуля: Необходимость воспроизводить обучение на тех же данных с теми же гиперпараметрами. У OLMo это возможно, у остальных — нет.
- Простота внесения изменений в код обучения: Насколько легко модифицировать код (например, на PyTorch vs. JAX vs. собственный фреймворк). OLMo — на PyTorch, что упрощает модификации.
- Лицензия на модификации: Важно для экспериментов (можно ли коммерчески использовать результаты модификаций). У Llama, Qwen, Gemma ограничения.
- Документированность ошибок и багов: Насколько открыта разработка (Issues, PR, roadmap). У OLMo всё в открытом GitHub.

5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в качестве долгосрочного экспериментального стенда?

- Ограниченный выбор размеров: OLMo выпускает только 1B, 7B (и недавно 13B). Отсутствие 70B+ модели может быть ограничением для масштабных экспериментов.
- Меньшее сообщество: По сравнению с Llama, у OLMo меньше готовых доработок, туториалов и примеров.
- Развитие проекта: AI2 — исследовательский институт, финансирование которого может измениться, но OLMo — стратегический проект, и он активно развивается.
- Сложность запуска 7B: 7B модель требует ~14-16 ГБ VRAM для полной точности (FP16), что под силу не каждому GPU. 1B модель — стартовый вариант.
- Отсутствие поддержки популярных инструментов: Некоторые инструменты (например, vLLM) могут не иметь полноценной поддержки OLMo, что потребует самостоятельной адаптации.

Вердикт

Если твоя цель — создать стенд для глубокого инженерного исследования (модификация внимания, замена токенизатора, анализ внутренних представлений), OLMo — твой выбор. Если же нужна просто рабочая модель и ты не планируешь её модифицировать — можно взять Llama или Mistral. Но как экспериментальный стенд, OLMo вне конкуренции.

Вывод Gemini :

Анализ кандидатов

1. OLMo (Allen Institute for AI / AI2)

- **Краткое описание:** Семейство полностью открытых (Truly Open-Source) языковых моделей, созданное Allen Institute for AI с явным фокусом на научную воспроизводимость и академические исследования.
- **Сильные стороны:**
 - **100% прозрачность:** Открыты не только веса и архитектура, но и исходный датасет (Dolma/Dolma2), весь код препроцессинга, кода обучения (Dolma CLI, OLMo-Core), а также промежуточные чекпоинты (checkpoints) на разных этапах обучения.
 - **Документированность:** Исчерпывающие технические отчеты (technical papers) подробно описывают токенизатор, динамику обучения, гиперпараметры и архитектурные решения.
 - **Модульность:** Код написан на чистом PyTorch без избыточных обёрток, что делает отключение, замену или модификацию отдельных блоков (например, механизмов внимания или слоёв Feed-Forward) максимально простой.
- **Слабые стороны:**
 - Меньший экосистемный охват оптимизированных коммерческих инференс-движков (таких как TensorRT-LLM) по сравнению с Llama.
- **Ограничения:** Лицензия Apache 2.0 или ODC-By дает полную свободу исследований, но масштабы экосистемы сторонних библиотек чуть уступают гигантам.
- **Возможные инженерные риски:** Зависимость от инфраструктурных скриптов AI2 при попытке полной повторной сборки pipeline с нуля.
- **Общая оценка: Идеальный лабораторный объект.** Это одна из редких моделей, отвечающих требованиям классического научного эксперимента.

2. Llama (Meta)

- **Краткое описание:** Промышленный стандарт среди открытых Weights-Available моделей.
- **Сильные стороны:**
 - Огромная экосистема инструментов для исследования (TransformerLens, Catch, Llama-Score, библиотеки механо-интерпретируемости).
 - Полная поддержка всеми фреймворками локального запуска и модификации (llama.cpp, vLLM, Hugging Face transformers).
 - Детально описанный токенизатор (Tiktoken-based) и архитектура (RoPE, GQA, SwiGLU).
- **Слабые стороны:**
 - Датасеты обучения закрыты (описаны лишь высокоуровнево в техническом отчете).
 - Процесс обучения невоспроизводим извне, чекпоинты промежуточных шагов обучения (training steps) не публикуются.
- **Ограничения:** Кастомная лицензия Llama Materials License с ограничениями по

коммерческому масштабированию и запретом на использование выходов для обучения других моделей.

- **Возможные инженерные риски:** Невозможность исследовать влияние конкретных паттернов обучающих данных на внутренние активации.
- **Общая оценка:** Прекрасная база для инженерных модификаций и интерпретируемости, но с ограниченной научной прозрачностью.

3. Gemma (Google)

- **Краткое описание:** Семейство lightweight-моделей от Google, построенное с использованием тех же архитектурных и технологических решений, что и флагманская серия Gemini.
- **Сильные стороны:**
 - Доступность специализированных исследовательских инструментов механо-интерпретируемости (Gemma Scope — открытые Sparse Autoencoders для визуализации и модификации внутренних концептов).
 - Высокое качество инженерной реализации архитектурных блоков (Multi-Query Attention / GQA, RoPE, RMSNorm).
- **Слабые стороны:**
 - Закрытый обучающий датасет и отсутствие промежуточных чекпоинтов.
 - Особенности токенизатора (большой словарь, специфические флаговые токены) иногда услождают низкоуровневые манипуляции.
- **Ограничения:** Условия использования Gemma Terms of Use ограничены правилами допустимого использования Google.
- **Возможные инженерные риски:** Риск "черного ящика" в части исходных данных при попытке глубокого анализа причин появления галлюцинаций или специфических активаций.
- **Общая оценка:** Отличная платформа для исследований в области Interpretability & Steering благодаря Gemma Scope, но не для исследования процессов обучения.

4. Qwen (Alibaba Cloud)

- **Краткое описание:** Мощное открытое семейство моделей от Alibaba, демонстрирующее отличные инженерные и архитектурные показатели.
- **Сильные стороны:**
 - Отличная инженерная документация по архитектуре и квантованию.
 - Поддержка длинного контекста, продвинутых механизмов токенизации и гибридных архитектур (Qwen-MoE).
 - Развитая инфраструктура локального запуска.
- **Слабые стороны:**
 - Полностью закрытые обучающие данные и пайплайны фильтрации.
 - Ограниченные сведения о fine-tuning / RLHF пайплайнах.
- **Ограничения:** Лицензирование варьируется от Apache 2.0 до кастомных ограничений в зависимости от размера модели.
- **Возможные инженерные риски:** Риск модификации базовых реализаций в

официальном репозитории без сохранения обратной совместимости.

- **Общая оценка:** Сильный претендент для прикладной инженерии, но уступающий в фундаментальной открытости.

5. Mistral / Mixtral (Mistral AI)

- **Краткое описание:** Евразийский флагман открытых моделей, популяризовавший архитектуры Sliding Window Attention и Sparse Mixture of Experts (MoE).
- **Сильные стороны:**
 - Лаконичность исходного кода базовых реализаций.
 - Эффективный механизм внимания (Sliding Window Attention) и реализация MoE (для Mixtral).
- **Слабые стороны:**
 - Минималистичные технические отчеты (Technical Reports) со скудным описанием процесса обучения и рецептуры данных.
 - Отсутствие открытых чекпоинтов процесса обучения.
- **Ограничения:** Отдельные модели поставляются под Apache 2.0, более новые — под коммерческими или исследовательскими лицензиями.
- **Возможные инженерные риски:** Нехватка официальной информации о внутренних механизмах фильтрации и токенизации.
- **Общая оценка:** Инженерно элегантная модель, но «скупая» на исследовательскую документацию.

6. Falcon (TII)

- **Краткое описание:** Семейство моделей от Технологического инновационного института (TII, ОАЭ), использовавшее архитектуру Multi-Query Attention и сфокусированное на параллельном выполнении слоев.
- **Сильные стороны:**
 - Полностью открытая лицензия Apache 2.0.
 - Публикация датасета RefinedWeb (для ранних версий).
- **Слабые стороны:**
 - Нестандартные архитектурные решения (параллельные слои Attention и MLP) иногда затрудняют интеграцию со стандартными инструментами интерпретируемости.
 - Замедление развития экосистемы инструментария по сравнению с Llama и Qwen.
- **Ограничения:** Меньшее число сторонних библиотек для механо-интерпретируемости.
- **Возможные инженерные риски:** Риск морального устаревания экосистемной поддержки инструментария.
- **Общая оценка:** Хороший исторический пример, но уступающий современным альтернативам по уровню исследовательской инфраструктуры.

Альтернативные кандидаты (включены по критериям открытости)

- **Pythia (EleutherAI):** Специально созданное семейство моделей (от 70М до 12В параметров) именно для инженерных и научных исследований.
 - *Плюсы:* 154 промежуточных чекпоинта на каждый размер модели, полностью открытый датасет (The Pile), идентичный порядок подачи данных при обучении.
 - *Минусы:* Архитектурно базируется на более старых стандартах (NeoX), но является золотым стандартом для анализа динамики обучения.

Сравнительная таблица критериев

Критерий	OLMo	Llama	Gemma	Qwen	Mistral	Falcon	Pythia
1. Открытость архитектуры	Высокая	Высокая	Высокая	Высокая	Высокая	Высокая	Высокая
2. Доступность весов	Да	Да	Да	Да	Да	Да	Да
3. Полнота тех. документации	Высшая	Высокая	Средняя	Средняя	Низкая	Средняя	Высшая
4. Документированность обучения	Полная	Низкая	Низкая	Низкая	Отсутствует	Средняя	Полная
5. Докум	Полная	Полная	Полная	Полная	Средняя	Средняя	Полная

ентиро ваннос ть токени затора					я	я	
6. Докум ентиро ваннос ть Attenti on	Полная	Полная	Полная	Полная	Полная	Полная	Полная
7. Локаль ный запуск	Да	Да	Да	Да	Да	Да	Да
8. Локаль ная модиф икация	Проста я	Средня я	Средня я	Средня я	Средня я	Сложн ая	Проста я
9. Отклю чение/ замена блоков	Высока я	Средня я	Средня я	Средня я	Средня я	Низкая	Высока я
10. Инстру менты исслед ования	Отличн ые	Богате йшие	Gemma Score	Средни е	Базовы е	Базовы е	Отличн ые

11. Воспроизводимость	Полная	Частичная	Частичная	Частичная	Низкая	Частичная	Полная
12. Сообщество	Научное	Массовое	Огранич.	Массовое	Среднее	Небольшое	Научное
13. Долгосрочная поддержка	AI2 (Высок)	Meta (Высок)	Google (Высок)	Alibaba (Высок)	Средняя	TII (Сред)	EleutherAI
14. Пригодность как стенд	Высшая	Высокая	Высокая	Средняя	Средняя	Низкая	Высшая

Итоговый анализ

1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?

Наиболее подходящей моделью является **OLMo (Allen Institute for AI)** (а для задач низкоуровневого анализа динамики обучения — **Pythia от EleutherAI**).

2. Почему именно она?

- Принцип «White Box» (Белый ящик):** OLMo — единственное полноценное современное семейство, предоставляющее полную цепочку: *Данные (Dolma) $\rightarrow$ Код сборки $\rightarrow$ Код обучения $\rightarrow$ Промежуточные чекпоинты $\rightarrow$ Beca $\rightarrow$ Оценка.*
- Модульность PyTorch-кода:** Исходный код не перегружен проприетарными абстракциями. Инженеру легко совершать хирургические вмешательства: подменять слои внимания, изменять матрицы RoPE, вставлять кастомные функции активации или измерять промежуточные тензоры без взлома сторонних библиотек.
- Воспроизводимость:** Вы можете верифицировать любую гипотезу (например, о

влиянии конкретного слоя на галлюцинации), откатавшись к промежуточному чекпоинту или проверив состав датасета.

3. Какая модель занимает второе место?

Второе место занимает **Llama (Meta)**.

- **Причина:** Несмотря на закрытость данных и процесса обучения, Llama обладает **наибольшей экосистемой готовности**. Для неё созданы тысячи сторонних утилит (от TransformerLens до специализированных фреймворков внедрения зондов в матрицы весов). Если цель эксперимента не включает исследование *процесса обучения*, а сфокусирована на *модификации готовых весов и архитектурных механизмах*, Llama — отличный выбор.

4. Какие критерии выбора отсутствовали в данном исследовании

1. **Лицензионная чистота и юридические риски:** Наличие патентных оговорок или ограничений по типу коммерческого использования (как у Llama).
2. **Аппаратные требования для исследования (Hardware Footprint):** Требования к VRAM для сохранения графа вычислений при глубоком дампе активаций всех слоев на длинных контекстах.
3. **Чистота реализации кодовой базы в Hugging Face / Native PyTorch:** Некоторые модели имеют сложные кастомные скрипты (`trust_remote_code=True`), что затрудняет их статическую модификацию и патчинг.
4. **Устойчивость к квантованию (Quantization Sensitivity):** Насколько архитектура сохраняет работоспособность при сжатии до INT4/FP8 при локальных тестах.

5. Потенциальные проблемы при использовании выбранной модели (OLMo) как долгосрочного стенда

- **Инфраструктурное отставание экосистемы:** Популяризация новых методов инференса (например, FlashAttention-3, специфика vLLM) в первую очередь оптимизируется под Llama и Qwen. Для OLMo некоторые адаптеры придется писать или дорабатывать вручную.
- **Меньший объем готовых Fine-Tuning датасетов:** По сравнению с Llama-экосистемой, сообщество готовых LoRA-адаптеров для OLMo меньше.
- **Ресурсоемкость полных экспериментов:** Если стенд предполагать с перезапуском этапов обучения на своих данных, работа с исходным датасетом Dolma (несколько терабайт) потребует серьезных дисковых и вычислительных ресурсов.

С чего планируешь начать работу над стендом — с выделения модулей для внедрения зондов (probes/interventions) или с изоляции механизмов внимания?



White Paper: Выбор эталонной open-source LLM для инженерного экспериментального стенда

Аннотация

В настоящем документе рассматривается задача выбора открытой языковой модели в качестве эталонной инженерной платформы для воспроизводимых экспериментов, анализа внутренних механизмов и контролируемых модификаций. В отличие от задач сравнения по качеству генерации, здесь приоритет отдан открытости архитектуры, доступности артефактов обучения, полноте технической документации, локальной воспроизводимости и пригодности модели как лабораторного объекта исследования. На основе сравнительного анализа семейств OLMo, Qwen, Llama, Mistral, Gemma и Falcon сделан вывод, что наиболее подходящей платформой для долгосрочного экспериментального стенда является OLMo, а Qwen выступает как сильный практический альтернативный вариант. ^{[1] [2] [3]}

Введение

Пост числа open-weight и open-source языковых моделей сделал возможным не только прикладное использование LLM, но и их систематическое инженерное исследование. Однако для экспериментального стенда важна не максимальная “умность” модели, а полнота научной и инженерной открытости: доступ к весам, коду, данным, процедурам обучения, промежуточным чекпойнтам и сопутствующей документации. Именно эти свойства определяют, насколько модель пригодна для воспроизводимых абляций, вмешательства в архитектуру и анализа причинно-следственных связей между компонентами. ^{[3] [4] [1]}

Данный white paper отвечает на вопрос, какая открытая LLM наиболее подходит в качестве эталонной платформы для инженерного стенда. Исследование намеренно не оценивает субъективное качество генерации текста и не опирается на рыночную популярность. Вместо этого анализируется исследовательская пригодность модели как “лабораторного объекта”, допускающего модификации и длительное наблюдение.

Методология

Оценка проводилась по набору критериев, ориентированных на инженерную прозрачность и экспериментальную воспроизводимость. В частности, учитывались: открытость архитектуры, доступность весов, полнота технической документации, документированность процесса обучения, описание токенизатора и механизма внимания, возможность локального запуска, локальной модификации и отключения компонентов, наличие инструментов исследования внутренних механизмов, качество воспроизводимости, размер исследовательского сообщества, а также перспективы долговременной поддержки проекта. Эти критерии согласуются с задачей выбора не “лучшей” модели в общем смысле, а наиболее удобной основы для контролируемых научно-инженерных экспериментов. ^{[5] [6] [7] [1]}

Источниковая база включает официальную документацию моделей, model cards, технические отчёты и материалы разработчиков. Для OLMo использованы материалы Ai2, подчёркивающие полный жизненный цикл модели и открытость данных и артефактов; для Qwen — технические отчёты и публикации семейства Qwen3; для Llama — официальные model cards и технические сведения по архитектуре; для Mistral и Gemma — официальные docs и technical reports; для Falcon — официальные страницы и технические материалы. ^[2]
^{[6] [7] [8] [9] [10] [11] [3]}

Критерии инженерной пригодности

Для лабораторного стенда наибольшее значение имеют следующие свойства.

Во-первых, модель должна быть достаточным образом открыта, чтобы исследователь мог не только запускать инференс, но и реконструировать причины поведения системы. Во-вторых, требуется доступ к повторяемым артефактам обучения: без этого невозможно уверенно интерпретировать эффекты данных, рецептов pretraining и post-training. В-третьих, модель должна быть совместима с локальной средой выполнения и допускать модификацию отдельных блоков, включая токенизацию, внимание и слои нормализации. Наконец, долгосрочная пригодность определяется стабильностью релизов, активностью сообщества и наличием экосистемы инструментов анализа и абляций. ^{[4] [7] [1] [3]}

Анализ семейств моделей

OLMo

OLMo является наиболее сильным кандидатом с точки зрения инженерной прозрачности. Материалы проекта Ai2 подчёркивают не только открытые веса и код, но и доступ к полному жизненному циклу модели, включая данные, чекпойнты, зависимости и сопутствующие компоненты процесса обучения. Такая степень раскрытия особенно ценна для исследовательского стенда, поскольку позволяет проводить воспроизводимые эксперименты и проследивать влияние отдельных этапов пайплайна на итоговое поведение модели. ^{[1] [3] [4]}

С инженерной точки зрения сильнейшая сторона OLMo состоит в том, что это не просто open-weight проект, а максимально близкий к fully open подход. Это снижает методологические ограничения при изучении токенизации, качества данных, стадий обучения и последующих вмешательств в архитектуру или рецепты оптимизации. Ограничения OLMo связаны не с отсутствием прозрачности, а с относительно меньшей зрелостью прикладной экосистемы по сравнению с более массовыми семействами. Тем не менее для роли эталонного лабораторного объекта именно полнота открытости является решающим фактором. ^{[3] [4] [1]}

Qwen

Qwen представляет собой один из наиболее сильных open-weight семейств, сочетающий зрелую инженерную документацию, широкий диапазон размеров моделей и активную экосистему. Технический отчёт Qwen3 и сопутствующие материалы указывают на высокую практическую открытость семейства, а также на наличие хорошо задокументированных архитектурных и обучающих решений. Это делает Qwen особенно удобным для локального запуска, сравнительных тестов и инженерных абляций. ^{[11] [12] [2]}

Однако по сравнению с OLMo Qwen обычно уступает в степени раскрытия полного жизненного цикла модели. Для задач, где важна не только возможность инференса и адаптации, но и полная реконструкция исследовательского процесса, Qwen оказывается вторым по силе кандидатом. Его главное достоинство — баланс между открытостью, зрелостью экосистемы и удобством практической работы. ^{[12] [2] [11]}

Llama

Llama исторически является одной из наиболее влиятельных open-weight платформ, а официальные model cards содержат важные сведения по архитектуре, включая применение Grouped-Query Attention, особенности токенизатора и параметры контекстного окна. Эта документация делает Llama удобной для инженерного анализа и совместимой с большим числом инструментов и библиотек. ^{[7] [13] [14]}

Тем не менее Llama не является оптимальным кандидатом именно для исследовательского эталона, поскольку степень открытости обучения и полного набора артефактов уступает OLMo. Иными словами, Llama очень сильна как базовая инженерная платформа и как стандарт де-факто для совместимости, но не как максимально прозрачный лабораторный объект. ^{[13] [14] [7]}

Mistral

Mistral обладает сильной инженерной документацией и современными open-weight релизами, включая модели с MoE-архитектурой и хорошо описанными сценариями развертывания. Это делает семейство привлекательным для практических экспериментов и локального инференса. ^{[15] [16] [17] [5]}

С позиции white paper, однако, Mistral представляет собой в большей степени зрелую прикладную open-weight экосистему, чем fully open исследовательскую платформу. Сложность MoE-моделей также увеличивает нагрузку на интерпретацию и воспроизводимость. Поэтому Mistral следует рассматривать как сильный инженерный вариант, но не как наиболее прозрачный эталон. ^{[16] [17] [18] [5]}

Gemma

Gemma отличается аккуратной и подробной официальной документацией, включая model cards и technical reports, а также ясным описанием архитектурных решений. Это делает семейство удобным для исследователей, которым важны стандартизированные архитектуры, понятные ограничения и хорошая документация на уровне модели. ^{[6] [8] [19] [20]}

Тем не менее Gemma не обеспечивает того же уровня полного раскрытия жизненного цикла, что и OLMo. Она лучше подходит как хорошо документированный open-weight объект для сравнений и локальных экспериментов, чем как максимально открытая база для реконструкции и изменения каждого этапа разработки. ^{[8] [19] [20] [6]}

Falcon

Falcon имеет историческое значение как одно из заметных открытых семейств, а его технические материалы содержат сведения об архитектуре, токенизаторе и обучающем корпусе. Это делает его полезным для сравнительного анализа и ретроспективных исследований. ^{[9] [10] [21] [22]}

Однако в контексте выбора долгосрочного стенда Falcon уступает более современным семействам по активности экосистемы, зрелости сопутствующих инструментов и актуальности инженерной базы. Для лабораторной платформы важно не только наличие документов, но и способность проекта оставаться

удобным объектом исследования на протяжении длительного времени. По этому признаку Falcon выглядит менее предпочтительным.

[\[10\]](#) [\[21\]](#) [\[22\]](#) [\[9\]](#)

Сравнительная оценка

Ниже приведена качественная сравнительная таблица по ключевым критериям.

Модель	Открытость архитектуры	Доступность весов	Полнота документации	Документированность обучения	Токенизатор	Attention	Локальный запуск	Локальная модификация	Инструменты внутреннего анализа	Во
OLMo	Очень высокая	Очень высокая	Очень высокая	Очень высокая	Высокая	Высокая	Да	Да	Да	Оч
Qwen	Высокая	Высокая	Высокая	Средне-высокая	Высокая	Высокая	Да	Да	Да	Вы
Llama	Средне-высокая	Высокая	Высокая	Средняя	Высокая	Высокая	Да	Да	Частично	Ср
Mistral	Высокая	Высокая	Высокая	Средняя	Высокая	Высокая	Да	Да	Частично	Ср
Gemma	Средне-высокая	Высокая	Высокая	Средняя	Высокая	Высокая	Да	Да	Частично	Ср
Falcon	Средняя	Высокая	Средняя	Средняя	Средняя	Средняя	Да	Да	Ограниченно	Ср

Обсуждение результатов

Из проведённого анализа следует, что критерии инженерной пригодности не совпадают с критериями прикладной мощи модели. Наиболее мощные или популярные модели не обязательно являются наиболее удобными исследовательскими объектами. Для стенда важна не только производительность, но и возможность объяснить, воспроизвести и изменить поведение системы на уровне данных, архитектуры и процесса обучения. Именно поэтому OLMo оказывается предпочтительнее семейства, более сильного в практической экосистеме, но менее полного в плане раскрытия исследовательского пайплайна.

[\[2\]](#) [\[1\]](#) [\[3\]](#)

Qwen занимает второе место благодаря сочетанию открытых весов, сильной документации и зрелой инженерной базы. Для многих практических лабораторий именно Qwen станет наиболее удобным компромиссом между прозрачностью и эксплуатационной зрелостью. Однако если приоритетом является именно научная реконструкция и полный контроль над артефактами, OLMo остаётся более строгим выбором.

[\[11\]](#) [\[12\]](#) [\[2\]](#)

Ограничения исследования

Настоящий анализ имеет несколько ограничений. Во-первых, характеристики open-source моделей быстро меняются от релиза к релизу, поэтому выводы следует интерпретировать в привязке к конкретным версиям и датам публикации. Во-вторых, формальная открытость документации не всегда равна фактической пригодности для воспроизводимых экспериментов: важны также стабильность репозиторий, полнота release artifacts и удобство инфраструктуры. В-третьих, оценка “долгосрочной поддержки” частично носит прогнозный характер и зависит от дальнейшей политики разработчиков.

[\[6\]](#) [\[7\]](#) [\[11\]](#) [\[2\]](#)

Заключение

Наиболее подходящей open-source LLM в качестве эталонной инженерной платформы для экспериментального стенда является **OLMo**. Ключевая причина заключается в том, что этот проект наиболее близок к fully open исследовательской парадигме: он предоставляет доступ не только к весам и коду, но и к данным, чекпойнтам и полному жизненному циклу модели, что критически важно для воспроизводимых экспериментов и контролируемых модификаций.

[\[4\]](#) [\[1\]](#) [\[3\]](#)

Второе место занимает **Qwen**, который отличается сильной документацией, широкой экосистемой и хорошей инженерной пригодностью, но уступает OLMo по степени прозрачности полного процесса разработки. Llama, Mistral и Gemma остаются очень сильными кандидатами для прикладных и сравнительных исследований, тогда как Falcon представляет интерес главным образом как исторически важное семейство, но уже не как оптимальный современный эталонный стенд.

[\[7\]](#) [\[10\]](#) [\[12\]](#) [\[2\]](#) [\[6\]](#) [\[11\]](#)

Если хочешь, я могу следующим сообщением превратить этот white paper в ещё более “публикационный” вид:

- с **формальным academic style**;
- с **нумерацией разделов 1–6**;
- с **разделом References**;
- и с **оформлением под LaTeX / Markdown для статьи**.

Вывод от Qwen:

1. Анализ кандидатов

***OLMo (Allen Institute for AI)**

- **Краткое описание**: Семейство моделей, созданное специально для ускорения научных исследований в области языковых моделей, с акцентом на полную прозрачность.
- **Сильные стороны**: Беспрецедентная открытость: доступны не только веса, но и полный код обучения, логи, все промежуточные чекпоинты и обучающие данные (корпус Dolma). Отличная документация токенизатора и архитектуры.
- **Слабые стороны**: Сообщество и экосистема сторонних инженерных инструментов пока уступают по масштабу Llama или Qwen.
- **Ограничения**: Модели могут уступать в "сырой" производительности проприетарным аналогам, но это не является приоритетом по условию задачи.
- **Возможные инженерные риски**: Зависимость от долгосрочной поддержки специфических исследовательских инструментов со стороны Allen AI.
- **Общая оценка**: Искключительно высокая пригодность. Это один из лучших вариантов для воспроизводимых экспериментов.

***Pythia (EleutherAI) и LLM360 (Amber, K2)** *(Добавлены как превосходящие по инженерным характеристикам)*

- **Краткое описание**: Pythia специально разработана для изучения интерпретируемости и динамики обучения. LLM360 (проекты Amber и K2) предоставляет полностью воспроизводимый пайплайн от данных до финальных весов.
- **Сильные стороны**: Максимальная воспроизводимость. Открыты все промежуточные чекпоинты, что критически важно для изучения динамики обучения и механистической интерпретируемости. Полная документация токенизатора и процесса обучения.
- **Слабые стороны**: Относительно меньшие размеры моделей и меньший вычислительный бюджет обучения по сравнению с корпоративными гигантами.
- **Ограничения**: Не оптимизированы для продакшена, созданы исключительно для исследований.
- **Возможные инженерные риски**: Проект может быть менее стабилен в долгосрочной поддержке по сравнению с крупными корпорациями.
- **Общая оценка**: Эталонный выбор для глубокого изучения внутренних механизмов и контролируемых модификаций.

***Llama 3 (Meta)**

- **Краткое описание**: Семейство моделей с открытыми весами, использующее архитектуру transformer с Grouped-Query Attention (GQA) и токенизатором на 128 000 токенов.
- **Сильные стороны**: Огромное сообщество, обилие инженерных инструментов для локального запуска и модификаций (vLLM, Hugging Face, TransformerLens). Отличная документация архитектуры.
- **Слабые стороны**: Данные и код обучения не открыты. У меня нет информации о точных пропорциях и составе обучающих данных Llama 3, так как разработчики предоставляют только высокоуровневые описания (например, указание на наличие >5% высококачественного неанглийского текста).
- **Ограничения**: Невозможность точно воспроизвести процесс обучения с нуля.
- **Возможные инженерные риски**: Лицензионные ограничения могут усложнить некоторые виды модификаций или перелицензирования модифицированных версий.
- **Общая оценка**: Хороша для изучения архитектуры и модификации инференса, но не подходит как полностью воспроизводимый стенд обучения.

***Mistral (Mistral AI)**

- **Краткое описание**: Модели с открытыми весами, известные эффективной архитектурой, включая Sliding Window Attention, GQA и Rotary Position Embedding (RoPE).
- **Сильные стороны**: Высокая эффективность, хорошая документация архитектуры и механизмов внимания.
- **Слабые стороны**: Закрытые данные обучения и код обучения. Токенизатор документирован, но детали микса данных отсутствуют.
- **Ограничения**: Непригодна для полного воспроизведения процесса обучения.
- **Возможные инженерные риски**: Сдвиг компании в сторону проприетарных моделей может снизить внимание к поддержке открытых исследовательских инструментов.
- **Общая оценка**: Подходит для экспериментов с архитектурой внимания, но не как полностью прозрачный стенд.

***Qwen 2.5 (Alibaba)**

- **Краткое описание**: Семейство плотных decoder-only моделей с открытыми весами, обученных на 18 триллионах токенов.
- **Сильные стороны**: Отличная техническая документация, открытые веса, хорошая поддержка инструментов. Токенизатор (BPE) хорошо документирован.
- **Слабые стороны**: Данные обучения не открыты полностью. У меня нет информации о точном составе и источниках этих 18 триллионов токенов.

1. <https://allenai.org/olmo>
2. <https://arxiv.org/html/2505.09388v1>
3. <https://arxiv.org/abs/2512.13961>
4. https://www.datocms-assets.com/64837/1765558567-olmo_3_technical_report-4.pdf
5. <https://huggingface.co/mistralai/Mistral-7B-Instruct-v0.3>
6. https://ai.google.dev/gemma/docs/core/model_card
7. https://github.com/meta-llama/llama-models/blob/main/models/llama3/MODEL_CARD.md
8. <https://arxiv.org/pdf/2607.02770.pdf>
9. <https://arxiv.org/html/2407.14885v1>
10. https://huggingface.co/docs/transformers/model_doc/falcon
11. <https://arxiv.org/pdf/2505.09388.pdf>
12. https://qianwen-res.oss-cn-beijing.aliyuncs.com/QWEN_TECHNICAL_REPORT.pdf
13. https://huggingface.co/docs/transformers/model_doc/llama
14. https://aiwiki.ai/wiki/llama_model_card
15. <https://docs.mistral.ai/models>
16. <https://docs.mistral.ai/models/model-cards/mistral-large-3-25-12>
17. <https://mistral.ai/models/>
18. https://dev.to/jangwook_kim_e31e7291ad98/mistral-large-3-the-675b-open-weight-moe-model-developer-guide-250a
19. <https://arxiv.org/html/2607.02770v1>
20. <https://storage.googleapis.com/deepmind-media/gemma/Gemma3Report.pdf>
21. <https://huggingface.co/tiiuae/falcon-11B>
22. <https://apxml.com/models/falcon2-11b>

- 39 - ****Ограничения****: Воспроизводимость обучения невозможна.
- 40 - ****Возможные инженерные риски****: Зависимость от будущей политики компании в области открытости исходного кода.
- 41 - ****Общая оценка****: Крепкий кандидат для экспериментов с инференсом и дообучением (fine-tuning), но не для изучения процесса обучения с нуля.
- 42
- 43 **#### ****Gemma 2 (Google)******
- 44 - ****Краткое описание****: Легковесные открытые модели, использующие чередование локального и глобального внимания и GQA.
- 45 - ****Сильные стороны****: Хорошая техническая документация (technical report), открытые веса, поддержка инструментов разработчика.
- 46 - ****Слабые стороны****: Данные обучения не открыты.
- 47 - ****Ограничения****: Неполная прозрачность по сравнению с OLMo или Pythia.
- 48 - ****Возможные инженерные риски****: Ограничения лицензии могут усложнить некоторые виды модификаций и коммерциализации результатов исследований.
- 49 - ****Общая оценка****: Хороший объект для изучения архитектурных инноваций (например, logit soft-capping), но не для полной воспроизводимости.
- 50
- 51 **#### ****Falcon (TI)******
- 52 - ****Краткое описание****: Модели с открытыми весами, использующие Multi-Query Attention и FlashAttention.
- 53 - ****Сильные стороны****: Открытые веса, хорошая документация архитектуры.
- 54 - ****Слабые стороны****: Данные обучения (RefinedWeb) описаны высокоуровнево, код обучения не полностью открыт для воспроизведения.
- 55 - ****Ограничения****: Меньшая активность исследовательского сообщества по сравнению с Llama или Qwen.
- 56 - ****Возможные инженерные риски****: Снижение темпов развития проекта по сравнению с конкурентами.
- 57 - ****Общая оценка****: Устаревает как эталон по сравнению с OLMo/LLM360 по критерию полной прозрачности.

58 ---

59 ---

60 ---

61 **### 2. Сравнительная таблица**

62	Модель	Открытость весов и архитектуры	Документация обучения и токенизатора	Возможность локальной модификации	Инструменты исследования (интерпретируемость)	Воспроизводимость обучения	Пригодность как стенд (1-10)
63							
64		:---	:---	:---	:---	:---	:---
65	**OLMo**	Полная	Полная (данные Dolma, код, логи)	Высокая	Высокая	**Полная**	**10**
66	**LLM360 / Pythia**	Полная	Полная (все чекпоинты, код)	Высокая	**Очень высокая**	**Полная**	**9.5**
67	**Llama 3**	Весов: Да, Код: Нет	Частичная (архитектура да, данные нет)	Высокая	Высокая	Отсутствует	7
68	**Mistral**	Весов: Да, Код: Нет	Частичная (архитектура да, данные нет)	Высокая	Средняя	Отсутствует	6.5
69	**Qwen 2.5**	Весов: Да, Код: Нет	Частичная (архитектура да, данные нет)	Высокая	Средняя	Отсутствует	7
70	**Gemma 2**	Весов: Да, Код: Нет	Частичная (архитектура да, данные нет)	Высокая	Средняя	Отсутствует	6.5
71	**Falcon**	Весов: Да, Код: Нет	Частичная	Средняя	Низкая	Отсутствует	5.5

72 ---

73 ---

74 ---

75 **### 3. Итоговый анализ**

76

77 ****1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?****

78 Наиболее подходящей моделью является ****OLMo**** (или проекты семейства ****LLM360****, такие как Amber/K2).

79

80 ****2. Почему именно она?****

81 Потому что это единственные модели, которые предоставляют полный доступ к обучающим данным (например, корпус Dolma), исходному коду обучения, логам и всем промежуточным чекпоинтам. Это является обязательным инженерным условием для "воспроизводимых экспериментов и последующих контролируемых модификаций", так как позволяет не только менять архитектуру, но и точно воспроизводить процесс обучения для проверки гипотез.

82

83 ****3. Какая модель занимает второе место?****

84 Второе место занимает **Pythia** от EleutherAI. Она была специально создана для изучения
динамики обучения и интерпретируемости, предоставляя исследователям все чекпоинты с самого
начала обучения, что критически важно для лабораторных экспериментов. Если же говорить о
моделях из исходного списка, то второе место занимает **Llama 3** исключительно за счет
огромного количества сторонних инженерных инструментов и документации по архитектуре, несмотр
на закрытость данных.

85

86 **4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?**

87 - **Наличие промежуточных чекпоинтов**: Критически важно для изучения динамики обучения
(learning dynamics), а не только финального состояния модели.

88 - **Лицензионная чистота для модификаций**: Возможность свободного изменения кода и
перелицензирования модифицированной версии без юридических барьеров (например, некоторые
лицензии запрещают использование результатов для обучения других моделей).

89 - **Нативная совместимость с фреймворками механистической интерпретируемости**: Например,
готовность архитектуры к загрузке в `TransformerLens` или `nnsight` без необходимости
написания сложных кастомных слоев.

90

91 **5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в
качестве долгосрочного экспериментального стенда?**

92 - **Дрейф зависимостей**: Библиотеки (PyTorch, Transformers) обновляются, и код обучения или
скрипты модификации, написанные сегодня, могут перестать работать через год, требуя постоянной
поддержки.

93 - **Аппаратные ограничения**: Полное воспроизведение обучения даже для 7B-моделей требует
значительных вычислительных кластеров. Для локальных экспериментов придется ограничиваться
микро-моделями или использовать методы вроде LoRA, что сужает класс возможных экспериментов.

94 - **Неопределенность данных**: У меня нет информации о точном составе обучающих данных для
моделей вроде Llama 3 или Qwen 2.5, так как разработчики предоставляют только высокоуровневые
описания. Это делает невозможным строгое воспроизведение их обучения, что является
фундаментальным ограничением для некоторых типов экспериментов.

1 EXP-001. Выбор эталонной открытой LLM для экспериментального стенда от SAKANA

2 Краткий разбор кандидатов

3 Llama (Meta)

4 ОписаниеСемейство моделей от Meta (Llama 2, 3, 4). Веса доступны, но с ограничениями по лицензии (Llama Community License). Архитектура — классический трансформер с некоторыми оптимизациями (GQA, RoPE и т.д.).

5 Сильные стороны

6

7 Веса доступны для локального запуска и экспериментов.

8 Огромное сообщество: множество форков, адаптаций, инструментов (llama.cpp, vLLM, Hugging Face).

9 Хорошо документированы API и практические руководства по развёртыванию.

10 Относительно простой трансформерный дизайн (не MoE), что упрощает модификацию.

11

12 Слабые стороны

13

14 Не полностью открытый стек: данные обучения и многие детали процесса скрыты.

15 Лицензия не Apache 2.0 / MIT, есть ограничения на крупных игроков и географию (особенно для мультимодальных версий).

16 Документация архитектуры и обучения скорее «обзорная», чем детальная.

17 Токенизатор и механизм внимания описаны на уровне общей схемы, но не до уровня полной воспроизводимости.

18

19 Ограничения

20

21 Нельзя полностью воспроизвести обучение с нуля по документации.

22 Нет полного набора инструментов для исследования внутренних механизмов «из коробки».

23

24 Инженерные риски

25

26 Зависимость от Meta в плане лицензии и будущих изменений.

27 Неполная прозрачность данных обучения может затруднить анализ поведения модели в узких доменах.

28

29 Общая оценкаХороший кандидат для практических экспериментов и локального запуска, но не идеальный стенд из-за недостаточной прозрачности стека и лицензионных нюансов.

30

31 OLMo (Allen Institute for AI)

32 ОписаниеOLMo — семейство полностью открытых языковых моделей от некоммерческого Allen Institute for AI. Архитектура — трансформер, обучение на открытых данных Dolma, код, данные и веса доступны под Apache 2.0.

33 Сильные стороны

34

35 Полная открытость: веса, код обучения, данные, конфигурации, логи.

36 Подробная техническая документация и научные статьи, описывающие архитектуру, токенизатор, механизм внимания, гиперпараметры.

37 Токенизатор и механизм внимания документированы на уровне, достаточном для воспроизведения.

38 Локальный запуск и модификация компонентов поддерживаются официальными репозиториями.

39 Есть инструменты для исследования внутренних механизмов (например, OLMoTracer для трассировки выходов к данным обучения).

40 Воспроизводимость результатов высокая: можно повторить обучение с нуля.

41 Активное исследовательское сообщество вокруг Ai2 и академических институтов.

42 Долговременная поддержка как со стороны Ai2, так и сообщества.

43

44 Слабые стороны

45

46 Модели относительно небольшие по сравнению с Llama 3.3/4 или Mistral Large (например, OLMo-3-32B против Llama 3.3 70B).

47 Меньше готовых прикладных инструментов «под ключ» по сравнению с Llama или Mistral.

48

49 Ограничения

50

51 Если нужны очень большие модели (сотни миллиардов параметров), OLMo пока уступает Llama/Mistral.

52

53 Инженерные риски

54

55 Риски минимальны: Apache 2.0, некоммерческий разработчик, прозрачный стек.

56

57 Общая оценкаНаиболее подходящая модель в качестве эталонной инженерной платформы из-за полной прозрачности, воспроизводимости и исследовательской направленности.

58

59 Mistral

60 ОписаниеMistral AI выпускает как открытые модели (Mistral 7B, Mixtral 8x7B, Mistral NeMo 12B под Apache 2.0), так и коммерческие (Mistral Large). Архитектура — трансформер, часто с Mixture-of-Experts (MoE).

61 Сильные стороны

62

63 Некоторые модели полностью открыты под Apache 2.0 (например, Mistral NeMo 12B).

64 Хорошая документация по API и развёртыванию.

65 Поддержка в популярных фреймворках (Hugging Face, vLLM, mistral.rs).

66 МоЕ-архитектура интересна для исследования эффективности и специализации экспертов.

67

68 Слабые стороны

69

70 Не все модели полностью открыты: часть доступна только через API или с ограничениями.

71 Данные обучения и детали процесса часто не раскрываются.

72 Документация архитектуры и механизмов внимания скорее обзорная.

73 Для МоЕ-моделей модификация компонентов сложнее из-за распределённой природы экспертов.

74

75 Ограничения

76

77 Воспроизведение обучения с нуля затруднено из-за недостатка данных и деталей.

78

79 Инженерные риски

80

81 Зависимость от коммерческой компании; стратегия открытости может меняться.

82 МоЕ усложняет эксперименты с заменой или отключением отдельных механизмов.

83

84 Общая оценкаХороший выбор для практических приложений и некоторых исследований, но не лучший стенд из-за неполной прозрачности стека.

85

86 Qwen (Alibaba Cloud)

87 ОписаниеСемейство моделей от Alibaba Cloud. Многие версии открыты под Apache 2.0 или близкими лицензиями. Архитектура — трансформер, часто с гибридным МоЕ и линейным вниманием.

88 Сильные стороны

89

90 Активное сообщество и множество инструментов (Qwen-Agent, ModelScope).

91 Хорошая документация по использованию и развёртыванию.

92 Поддержка мультимодальности и агентских возможностей.

93 Некоторые модели полностью открыты под Apache 2.0.

94

95 Слабые стороны

96

97 Не все модели одинаково открыты: есть проприетарные версии и лицензионные ограничения.

98 Данные обучения и детали процесса часто не раскрываются полностью.

99 Архитектура усложнена (гибридный МоЕ, линейное внимание), что затрудняет модификацию.

100 Документация архитектуры и механизмов внимания скорее обзорная.

101

102 Ограничения

103

104 Воспроизведение обучения с нуля затруднено.

105 Часть инструментов завязана на экосистему Alibaba.

106

107 Инженерные риски

108

109 Зависимость от китайской компании и её политики открытости.

110 Сложная архитектура увеличивает порог входа для глубоких модификаций.

111

112 Общая оценкаМощная и гибкая модель для приложений, но не идеальный стенд из-за неполной прозрачности и сложности архитектуры.

113

114 Gemma (Google DeepMind)

115 ОписаниеСемейство лёгких открытых моделей от Google DeepMind, основанных на технологии Gemini. Веса доступны, лицензия позволяет коммерческое использование.

116 Сильные стороны

117

118 Веса открыты, есть официальные библиотеки (gemma PyPI) и документация.

119	Хорошая интеграция с популярными фреймворками (JAX, PyTorch, TensorFlow, Hugging Face).
120	Активное сообщество и множество руководств по тонкой настройке.
121	Относительно простой трансформерный дизайн (для базовых версий).
122	
123	Слабые стороны
124	
125	Данные обучения и многие детали процесса скрыты.
126	Документация архитектуры и механизмов внимания скорее обзорная.
127	Неполная прозрачность стека обучения.
128	Нет инструментов для глубокого исследования внутренних механизмов «из коробки».
129	
130	Ограничения
131	
132	Воспроизведение обучения с нуля затруднено.
133	Модели ориентированы на лёгкость и эффективность, а не на максимальную прозрачность.
134	
135	Инженерные риски
136	
137	Зависимость от Google и его политики открытости.
138	Риск изменения лицензионных условий в будущем.
139	
140	Общая оценкаХороший выбор для прикладных экспериментов и лёгких моделей, но не лучший стенд из-за недостаточной прозрачности стека.
141	
142	Falcon (Technology Innovation Institute)
143	ОписаниеСемейство моделей от Technology Innovation Institute (ОАЭ). Веса доступны под Apache 2.0, архитектура — трансформер с некоторыми оптимизациями.
144	Сильные стороны
145	
146	Веса открыты под Apache 2.0.
147	Относительно простая трансформерная архитектура.
148	Поддержка в Hugging Face и других фреймворках.
149	
150	Слабые стороны
151	
152	Активность проекта и сообщества ниже, чем у Llama, Mistral или Qwen.
153	Документация архитектуры и обучения менее детальна.
154	Данные обучения и многие детали процесса скрыты.
155	Меньше инструментов для исследования внутренних механизмов.
156	
157	Ограничения
158	
159	Воспроизведение обучения с нуля затруднено.
160	Долговременная поддержка менее предсказуема.
161	
162	Инженерные риски
163	
164	Зависимость от одного института; активность проекта может снизиться.
165	
166	Общая оценкаИнтересный кандидат с точки зрения лицензии, но не лучший стенд из-за меньшей прозрачности и активности сообщества.
167	
168	Сравнительная таблица
169	Оценка по шкале:
170	
171	✔ — хорошо / полностью удовлетворяет критерию
172	⚠ — частично / с оговорками
173	✘ — плохо / не удовлетворяет критерию
174	
175	
176	
177	
178	Критерий
179	Llama
180	OLMo
181	Mistral
182	Qwen
183	Gemma
184	Falcon

185
186
187
188
189
190
191
192
193
194
195
196
197
198
199
200
201
202
203
204
205
206
207
208
209
210
211
212
213
214
215
216
217
218
219
220
221
222
223
224
225
226
227
228
229
230
231
232
233
234
235
236
237
238
239
240
241
242
243
244
245
246
247
248
249
250
251
252
253

Открытость архитектуры



Доступность весов



Полнота техдокументации



Документированность процесса обучения



Документированность токенизатора



Документированность механизма внимания



Возможность локального запуска



Возможность локальной модификации компонентов



254 

255 

256 

257 

258

259

260 Возможность отключения/замены механизмов

261 

262 

263 

264 

265 

266 

267

268

269 Инженерные инструменты исследования

270 

271 

272 

273 

274 

275 

276

277

278 Воспроизводимость результатов

279 

280 

281 

282 

283 

284 

285

286

287 Размер и активность сообщества

288 

289 

290 

291 

292 

293 

294

295

296 Долговременная поддержка

297 

298 

299 

300 

301 

302 

303

304

305 Пригодность как экспериментальный стенд

306 

307 

308 

309 

310 

311 

312

313

314

315 Итоговый анализ

316 1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?

317 OLMo (Allen Institute for AI).

318 2. Почему именно она?

319

320 Полная прозрачность стека: веса, код обучения, данные, конфигурации, логи — всё открыто под Apache 2.0.

321 Детальная документация: архитектура, токенизатор, механизм внимания, гиперпараметры описаны н

уровне, достаточном для воспроизведения.

322 Воспроизводимость: можно повторить обучение с нуля, проводить контролируемые эксперименты и абляции.

323 Инженерные инструменты: например, OLMoTrace для трассировки выходов к данным обучения.

324 Некоммерческий разработчик: меньше рисков изменения политики открытости.

325 Исследовательская направленность: модель изначально заточена под прозрачность и исследования, а не под коммерческий успех.

326

327 3. Какая модель занимает второе место?

328 Llama (Meta).

329 Причины:

330

331 Огромное сообщество и множество инструментов для локального запуска и модификации.

332 Относительно простая трансформерная архитектура.

333 Веса доступны для большинства сценариев.

334

335 Но она уступает OLMo по прозрачности стека обучения и лицензионной чистоте.

336 4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?

337

338 Сложность архитектуры: например, наличие MoE, гибридных механизмов внимания, которые усложняют модификацию и анализ.

339 Инфраструктурные требования: объём памяти, необходимость многопроцессорных систем, поддержка квантования.

340 Скорость итерации: насколько быстро можно переобучить модель или провести серию экспериментов

341 Интеграция с инструментами анализа: поддержка профилирования, визуализации внимания, интерпретируемости.

342 Стабильность API и форматов: насколько часто меняются конфигурации, форматы чекпоинтов, что может сломать долгосрочные эксперименты.

343

344 5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в качестве долгосрочного экспериментального стенда?

345

346 Масштабируемость: OLMo — не самые большие модели; если понадобятся сотни миллиардов параметров, придётся либо масштабировать инфраструктуру, либо переходить на другую модель.

347 Скорость развития: новые версии OLMo могут менять архитектуру или форматы данных, что потребует миграции экспериментов.

348 Инструменты: часть исследовательских инструментов (например, OLMoTrace) может требовать доработки под конкретные задачи.

349 Сообщество: хотя оно активно, оно меньше, чем у Llama или Mistral, поэтому некоторые нишевые проблемы могут решаться медленнее.

350 Данные обучения: несмотря на открытость, объём данных огромен; их обработка и анализ требуют серьёзных вычислительных ресурсов. EXP-001. Выбор эталонной открытой LLM для экспериментального стенда

351 Краткий разбор кандидатов

352 Llama (Meta)

353 Описание Семейство моделей от Meta (Llama 2, 3, 4). Веса доступны, но с ограничениями по лицензии (Llama Community License). Архитектура — классический трансформер с некоторыми оптимизациями (GQA, RoPE и т.д.).

354 Сильные стороны

355

356 Веса доступны для локального запуска и экспериментов.

357 Огромное сообщество: множество форков, адаптаций, инструментов (llama.cpp, vLLM, Hugging Face).

358 Хорошо документированы API и практические руководства по развёртыванию.

359 Относительно простой трансформерный дизайн (не MoE), что упрощает модификацию.

360

361 Слабые стороны

362

363 Не полностью открытый стек: данные обучения и многие детали процесса скрыты.

364 Лицензия не Apache 2.0 / MIT, есть ограничения на крупных игроков и географию (особенно для мультимодальных версий).

365 Документация архитектуры и обучения скорее «обзорная», чем детальная.

366 Токенизатор и механизм внимания описаны на уровне общей схемы, но не до уровня полной воспроизводимости.

367

368 Ограничения

369

370 Нельзя полностью воспроизвести обучение с нуля по документации.

371 Нет полного набора инструментов для исследования внутренних механизмов «из коробки».

372
373 Инженерные риски
374
375 Зависимость от Meta в плане лицензии и будущих изменений.
376 Неполная прозрачность данных обучения может затруднить анализ поведения модели в узких
доменах.
377
378 Общая оценкаХороший кандидат для практических экспериментов и локального запуска, но не
идеальный стенд из-за недостаточной прозрачности стека и лицензионных нюансов.
379
380 OLMo (Allen Institute for AI)
381 ОписаниеOLMo — семейство полностью открытых языковых моделей от некоммерческого Allen
Institute for AI. Архитектура — трансформер, обучение на открытых данных Dolma, код, данные и
веса доступны под Apache 2.0.
382 Сильные стороны
383
384 Полная открытость: веса, код обучения, данные, конфигурации, логи.
385 Подробная техническая документация и научные статьи, описывающие архитектуру, токенизатор,
механизм внимания, гиперпараметры.
386 Токенизатор и механизм внимания документированы на уровне, достаточном для воспроизведения.
387 Локальный запуск и модификация компонентов поддерживаются официальными репозиториями.
388 Есть инструменты для исследования внутренних механизмов (например, OLMoTrace для трассировки
выходов к данным обучения).
389 Воспроизводимость результатов высокая: можно повторить обучение с нуля.
390 Активное исследовательское сообщество вокруг Ai2 и академических институтов.
391 Долговременная поддержка как со стороны Ai2, так и сообщества.
392
393 Слабые стороны
394
395 Модели относительно небольшие по сравнению с Llama 3.3/4 или Mistral Large (например,
OLMo-3-32B против Llama 3.3 70B).
396 Меньше готовых прикладных инструментов «под ключ» по сравнению с Llama или Mistral.
397
398 Ограничения
399
400 Если нужны очень большие модели (сотни миллиардов параметров), OLMo пока уступает
Llama/Mistral.
401
402 Инженерные риски
403
404 Риски минимальны: Apache 2.0, некоммерческий разработчик, прозрачный стек.
405
406 Общая оценкаНаиболее подходящая модель в качестве эталонной инженерной платформы из-за полной
прозрачности, воспроизводимости и исследовательской направленности.
407
408 Mistral
409 ОписаниеMistral AI выпускает как открытые модели (Mistral 7B, Mixtral 8x7B, Mistral NeMo 12B
под Apache 2.0), так и коммерческие (Mistral Large). Архитектура — трансформер, часто с
Mixture-of-Experts (MoE).
410 Сильные стороны
411
412 Некоторые модели полностью открыты под Apache 2.0 (например, Mistral NeMo 12B).
413 Хорошая документация по API и развёртыванию.
414 Поддержка в популярных фреймворках (Hugging Face, vLLM, mistral.rs).
415 МоЕ-архитектура интересна для исследования эффективности и специализации экспертов.
416
417 Слабые стороны
418
419 Не все модели полностью открыты: часть доступна только через API или с ограничениями.
420 Данные обучения и детали процесса часто не раскрываются.
421 Документация архитектуры и механизмов внимания скорее обзорная.
422 Для МоЕ-моделей модификация компонентов сложнее из-за распределённой природы экспертов.
423
424 Ограничения
425
426 Воспроизведение обучения с нуля затруднено из-за недостатка данных и деталей.
427
428 Инженерные риски
429

430 Зависимость от коммерческой компании; стратегия открытости может меняться.
431 MoE усложняет эксперименты с заменой или отключением отдельных механизмов.
432
433 Общая оценкаХороший выбор для практических приложений и некоторых исследований, но не лучший
стенд из-за неполной прозрачности стека.

434
435 Qwen (Alibaba Cloud)
436 ОписаниеСемейство моделей от Alibaba Cloud. Многие версии открыты под Apache 2.0 или близкими
лицензиями. Архитектура — трансформер, часто с гибридным MoE и линейным вниманием.
437 Сильные стороны
438
439 Активное сообщество и множество инструментов (Qwen-Agent, ModelScope).
440 Хорошая документация по использованию и развёртыванию.
441 Поддержка мультимодальности и агентских возможностей.
442 Некоторые модели полностью открыты под Apache 2.0.

443
444 Слабые стороны
445
446 Не все модели одинаково открыты: есть проприетарные версии и лицензионные ограничения.
447 Данные обучения и детали процесса часто не раскрываются полностью.
448 Архитектура усложнена (гибридный MoE, линейное внимание), что затрудняет модификацию.
449 Документация архитектуры и механизмов внимания скорее обзорная.

450
451 Ограничения
452
453 Воспроизведение обучения с нуля затруднено.
454 Часть инструментов завязана на экосистему Alibaba.

455
456 Инженерные риски
457
458 Зависимость от китайской компании и её политики открытости.
459 Сложная архитектура увеличивает порог входа для глубоких модификаций.

460
461 Общая оценкаМощная и гибкая модель для приложений, но не идеальный стенд из-за неполной
прозрачности и сложности архитектуры.

462
463 Gemma (Google DeepMind)
464 ОписаниеСемейство лёгких открытых моделей от Google DeepMind, основанных на технологии Gemini.
Веса доступны, лицензия позволяет коммерческое использование.
465 Сильные стороны
466
467 Веса открыты, есть официальные библиотеки (gemma PyPI) и документация.
468 Хорошая интеграция с популярными фреймворками (JAX, PyTorch, TensorFlow, Hugging Face).
469 Активное сообщество и множество руководств по тонкой настройке.
470 Относительно простой трансформерный дизайн (для базовых версий).

471
472 Слабые стороны
473
474 Данные обучения и многие детали процесса скрыты.
475 Документация архитектуры и механизмов внимания скорее обзорная.
476 Неполная прозрачность стека обучения.
477 Нет инструментов для глубокого исследования внутренних механизмов «из коробки».

478
479 Ограничения
480
481 Воспроизведение обучения с нуля затруднено.
482 Модели ориентированы на лёгкость и эффективность, а не на максимальную прозрачность.

483
484 Инженерные риски
485
486 Зависимость от Google и его политики открытости.
487 Риск изменения лицензионных условий в будущем.

488
489 Общая оценкаХороший выбор для прикладных экспериментов и лёгких моделей, но не лучший стенд
из-за недостаточной прозрачности стека.

490
491 Falcon (Technology Innovation Institute)
492 ОписаниеСемейство моделей от Technology Innovation Institute (ОАЭ). Веса доступны под Apache
2.0, архитектура — трансформер с некоторыми оптимизациями.

493	Сильные стороны						
494							
495	Веса открыты под Apache 2.0.						
496	Относительно простая трансформерная архитектура.						
497	Поддержка в Hugging Face и других фреймворках.						
498							
499	Слабые стороны						
500							
501	Активность проекта и сообщества ниже, чем у Llama, Mistral или Qwen.						
502	Документация архитектуры и обучения менее детальна.						
503	Данные обучения и многие детали процесса скрыты.						
504	Меньше инструментов для исследования внутренних механизмов.						
505							
506	Ограничения						
507							
508	Воспроизведение обучения с нуля затруднено.						
509	Долговременная поддержка менее предсказуема.						
510							
511	Инженерные риски						
512							
513	Зависимость от одного института; активность проекта может снизиться.						
514							
515	Общая оценкаИнтересный кандидат с точки зрения лицензии, но не лучший стенд из-за меньшей прозрачности и активности сообщества.						
516							
517	Сравнительная таблица						
518	Оценка по шкале:						
519							
520	✔ — хорошо / полностью удовлетворяет критерию						
521	△ — частично / с оговорками						
522	✖ — плохо / не удовлетворяет критерию						
523							
524	Критерий	Llama	OLMo	Mistral	Qwen	Gemma	Falcon
525							
526	Открытость архитектуры	△	✔	△	△	△	△
527							
528	Доступность весов	✔	✔	✔	✔	✔	✔
529							
530	Полнота техдокументации	△	✔	△	△	△	△
531							
532	Документированность процесса обучения	✖	✔	✖	✖	✖	✖
533							
534	Документированность токенизатора	△	✔	△	△	△	△
535							
536	Документированность механизма внимания	△	✔	△	△	△	△
537							
538	Возможность локального запуска	✔	✔	✔	✔	✔	✔
539							
540	Возможность локал. модификации комп-тов	✔	✔	✔	△	✔	✔
541							
542	Возможность отключ./замены механизмов	✔	✔	△	△	✔	✔
543							
544	Инженерные инструменты исследования	△	✔	△	△	△	△
545							
546	Воспроизводимость результатов	✖	✔	✖	✖	✖	✖
547							
548	Размер и активность сообщества	✔	△	✔	✔	✔	△
549							
550	Долговременная поддержка	✔	✔	△	△	✔	△
551							
552	Пригодность как экспериментальный стенд	△	✔	△	△	△	△
553							
554							
555							
556	Итоговый анализ						
557	1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?						
558	OLMo (Allen Institute for AI).						
559	2. Почему именно она?						
560							

561 Полная прозрачность стека: веса, код обучения, данные, конфигурации, логи — всё открыто под Apache 2.0.

562 Детальная документация: архитектура, токенизатор, механизм внимания, гиперпараметры описаны на уровне, достаточном для воспроизведения.

563 Воспроизводимость: можно повторить обучение с нуля, проводить контролируемые эксперименты и абляции.

564 Инженерные инструменты: например, OLMoTrace для трассировки выходов к данным обучения.

565 Некоммерческий разработчик: меньше рисков изменения политики открытости.

566 Исследовательская направленность: модель изначально заточена под прозрачность и исследования, а не под коммерческий успех.

567

568 3. Какая модель занимает второе место?

569 Llama (Meta).

570 Причины:

571

572 Огромное сообщество и множество инструментов для локального запуска и модификации.

573 Относительно простая трансформерная архитектура.

574 Веса доступны для большинства сценариев.

575

576 Но она уступает OLMo по прозрачности стека обучения и лицензионной чистоте.

577 4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?

578

579 Сложность архитектуры: например, наличие MoE, гибридных механизмов внимания, которые усложняют модификацию и анализ.

580 Инфраструктурные требования: объём памяти, необходимость многопроцессорных систем, поддержка квантования.

581 Скорость итерации: насколько быстро можно переобучить модель или провести серию экспериментов.

582 Интеграция с инструментами анализа: поддержка профилирования, визуализации внимания, интерпретируемости.

583 Стабильность API и форматов: насколько часто меняются конфигурации, форматы чекпоинтов, что может сломать долгосрочные эксперименты.

584

585 5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в качестве долгосрочного экспериментального стенда?

586

587 Масштабируемость: OLMo — не самые большие модели; если понадобятся сотни миллиардов параметров, придётся либо масштабировать инфраструктуру, либо переходить на другую модель.

588 Скорость развития: новые версии OLMo могут менять архитектуру или форматы данных, что потребует миграции экспериментов.

589 Инструменты: часть исследовательских инструментов (например, OLMoTrace) может требовать доработки под конкретные задачи.

590 Сообщество: хотя оно активно, оно меньше, чем у Llama или Mistral, поэтому некоторые нишевые проблемы могут решаться медленнее.

591 Данные обучения: несмотря на открытость, объём данных огромен; их обработка и анализ требуют серьёзных вычислительных ресурсов.