

Анализ кандидатов

1. Llama (Meta)

- **Сильные стороны:** Огромное сообщество, множество инструментов (transformers, vLLM, llama.cpp), хорошо документированная архитектура.
- **Слабые стороны:** Веса распространяются по некоммерческой лицензии, процесс обучения документирован частично, нет полной открытости данных и кода обучения.
- **Ограничения:** Нет официального фреймворка для исследований внимания, модификации компонентов сложны из-за монолитной архитектуры.
- **Риски:** Зависимость от политики Meta, нельзя модифицировать для коммерческих целей.
- **Оценка:** Хороший инструмент, но плохой эталон для инженерных экспериментов.

2. OLMo (AI2)

- **Сильные стороны:** Полностью открытый стек — веса, код обучения, данные (Dolma), токенизатор, документация процесса обучения, механизм внимания (с поддержкой альтернатив). Есть готовые хуки для интроспекции внимания.
- **Слабые стороны:** Меньше сообщество, меньше готовых инструментов, чем у Llama.
- **Ограничения:** Только несколько размеров (1B, 7B) — нет 70B+.
- **Риски:** Меньше сторонних доработок, может потребоваться самостоятельная реализация некоторых инструментов.
- **Оценка:** Идеальный стенд для инженерных модификаций.

3. Mistral

- **Сильные стороны:** Отличная производительность, хорошая документация, эффективный токенизатор, поддерживает sliding window attention (документирован).
- **Слабые стороны:** Веса открыты, но код обучения и данные — нет. Токенизатор документирован, но без данных обучения.
- **Ограничения:** Архитектура известна, но неполная спецификация обучения.
- **Риски:** Нельзя воспроизвести обучение, модификации ограничены архитектурой.
- **Оценка:** Хорошая модель, но не подходит для глубокого инженерного анализа.

4. Qwen (Alibaba)

- **Сильные стороны:** Высокая производительность, поддержка длинных контекстов, активное сообщество, разнообразие размеров.
- **Слабые стороны:** Архитектура описана, но не полностью. Данные и код обучения закрыты. Лицензия ограничивает коммерческое использование.
- **Ограничения:** Требуется лицензионное соглашение. Токенизатор документирован, но неполно.
- **Риски:** Зависимость от Alibaba, политика может измениться.
- **Оценка:** Интересная модель, но не пригодна в качестве инженерного эталона из-за закрытости обучения.

5. Gemma (Google)

- **Сильные стороны:** Хорошая документация, поддержка от Google, понятная архитектура, веса открыты.

- **Слабые стороны:** Данные обучения и код — закрыты. Лицензия ограничивает использование.
- **Ограничения:** Только небольшой размер (2B/7B), токенизатор документирован, но без данных.
- **Риски:** Зависимость от Google, закрытость обучения.
- **Оценка:** Качественная модель, но не подходит как лабораторный стенд.

6. Falcon (TII)

- **Сильные стороны:** Полностью открытый стек, включая веса и данные обучения (RefinedWeb).
- **Слабые стороны:** Меньше сообщества, меньший выбор размеров (7B, 40B — 40B сложно локально).
- **Ограничения:** 40B требует много ресурсов, 7B — ограничена.
- **Риски:** Меньше активного развития, чем у OLMo.
- **Оценка:** Хороший вариант, но уступает OLMo в полноте стека.

7. Другие: Pythia, GPT-NeoX

- **Pythia (EleutherAI):** Специально создана для исследования обучения. Отличный выбор для анализа поведения моделей, но меньше фокус на модификацию архитектуры.
- **GPT-NeoX (EleutherAI):** Полностью открытый код обучения, но веса и данные закрыты (только код).

Сравнительная таблица

Критерий	Llama	OLMo	Mistral	Qwen	Gemma	Falcon
Открытость архитектуры	Частично	Полная	Частично	Частично	Частично	Полная
Доступность весов	Да (ограниченно)	Да (полностью)	Да	Да	Да	Да
Документация обучения	Частично	Полная	Нет	Нет	Нет	Полная
Документация токенизатора	Да	Полная	Да	Частично	Да	Да
Механизм внимания	Документирован	Полностью документирован	Документирован	Частично	Документирован	Документирован
Локальный запуск	Да	Да	Да	Да	Да	Да (7B)
Модификация компонентов	Сложно	Легко	Сложно	Сложно	Сложно	Сложно
Отключение/замена	Сложно	Легко	Сложно	Сложно	Сложно	Сложно

Критерий	Llama	OLMo	Mistral	Qwen	Gemma	Falcon
механизмов						
Инструменты исследования	Есть (частично)	Есть (специальные хуки)	Нет	Нет	Нет	Нет
Воспроизводимость	Нет	Да	Нет	Нет	Нет	Да
Сообщество	Огромное	Растет	Большое	Большое	Среднее	Среднее
Долговременная поддержка	Meta	AI2 (институт)	Mistral AI	Alibaba	Google	TII

Итоговый анализ

1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?

OLMo от AI2.

2. Почему именно она?

Потому что она единственная из списка предоставляет полностью открытый стек:

- Веса — без ограничений.
- Код обучения — полностью открыт.
- Данные (Dolma) — открыты и документированы.
- Токенизатор — полная спецификация.
- Механизм внимания — документирован и поддерживает модификации.
- Инструменты — есть готовые хуки для исследования внутренних механизмов.

Это делает её идеальным лабораторным объектом, где можно модифицировать внимание, отключать слои, менять токенизатор и знать, как это работает на всех уровнях.

3. Какая модель занимает второе место?

Falcon. Она также предоставляет полностью открытый стек (веса, код обучения, данные RefinedWeb), что делает её воспроизводимой. Однако у неё меньше выбор размеров, а 40B модель сложно запустить локально на одном GPU. OLMo выигрывает за счёт лучшей адаптации к экспериментам.

4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?

- Возможность точного воспроизведения с нуля: Необходимость воспроизводить обучение на тех же данных с теми же гиперпараметрами. У OLMo это возможно, у остальных — нет.
- Простота внесения изменений в код обучения: Насколько легко модифицировать код (например, на PyTorch vs. JAX vs. собственный фреймворк). OLMo — на PyTorch, что упрощает модификации.
- Лицензия на модификации: Важно для экспериментов (можно ли коммерчески использовать результаты модификаций). У Llama, Qwen, Gemma ограничения.
- Документированность ошибок и багов: Насколько открыта разработка (Issues, PR, roadmap). У OLMo всё в открытом GitHub.

5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в качестве долгосрочного экспериментального стенда?

- Ограниченный выбор размеров: OLMo выпускает только 1B, 7B (и недавно 13B). Отсутствие 70B+ модели может быть ограничением для масштабных экспериментов.
- Меньшее сообщество: По сравнению с Llama, у OLMo меньше готовых доработок, туториалов и примеров.
- Развитие проекта: AI2 — исследовательский институт, финансирование которого может измениться, но OLMo — стратегический проект, и он активно развивается.
- Сложность запуска 7B: 7B модель требует ~14-16 ГБ VRAM для полной точности (FP16), что под силу не каждому GPU. 1B модель — стартовый вариант.
- Отсутствие поддержки популярных инструментов: Некоторые инструменты (например, vLLM) могут не иметь полноценной поддержки OLMo, что потребует самостоятельной адаптации.

Вердикт

Если твоя цель — создать стенд для глубокого инженерного исследования (модификация внимания, замена токенизатора, анализ внутренних представлений), OLMo — твой выбор. Если же нужна просто рабочая модель и ты не планируешь её модифицировать — можно взять Llama или Mistral. Но как экспериментальный стенд, OLMo вне конкуренции.