

```
1 Вывод Qwen
2
3 ### 1. Анализ кандидатов
4
5 #### **OLMo (Allen Institute for AI)**
6 - **Краткое описание**: Семейство моделей, созданное специально для ускорения научных
7 исследований в области языковых моделей, с акцентом на полную прозрачность.
8 - **Сильные стороны**: Беспрецедентная открытость: доступны не только веса, но и полный код
9 обучения, логи, все промежуточные чекпоинты и обучающие данные (корпус Dolma). Отличная
10 документация токенизатора и архитектуры.
11 - **Слабые стороны**: Сообщество и экосистема сторонних инженерных инструментов пока уступают
12 по масштабу Llama или Qwen.
13 - **Ограничения**: Модели могут уступать в "сырой" производительности проприетарным аналогам,
14 но это не является приоритетом по условию задачи.
15 - **Возможные инженерные риски**: Зависимость от долгосрочной поддержки специфических
16 исследовательских инструментов со стороны Allen AI.
17 - **Общая оценка**: Исключительно высокая пригодность. Это один из лучших вариантов для
18 воспроизводимых экспериментов.
19
20 #### **Pythia (EleutherAI) и LLM360 (Amber, K2)** *(Добавлены как превосходящие по инженерным
21 характеристикам)*
22 - **Краткое описание**: Pythia специально разработана для изучения интерпретируемости и
23 динамики обучения. LLM360 (проекты Amber и K2) предоставляет полностью воспроизводимый
24 пайплайн от данных до финальных весов.
25 - **Сильные стороны**: Максимальная воспроизводимость. Открыты все промежуточные чекпоинты,
26 что критически важно для изучения динамики обучения и механистической интерпретируемости.
27 Полная документация токенизатора и процесса обучения.
28 - **Слабые стороны**: Относительно меньшие размеры моделей и меньший вычислительный бюджет
29 обучения по сравнению с корпоративными гигантами.
30 - **Ограничения**: Не оптимизированы для продакшена, созданы исключительно для исследований.
31 - **Возможные инженерные риски**: Проект может быть менее стабилен в долгосрочной поддержке по
32 сравнению с крупными корпорациями.
33 - **Общая оценка**: Эталонный выбор для глубокого изучения внутренних механизмов и
34 контролируемых модификаций.
35
36 #### **Llama 3 (Meta)**
37 - **Краткое описание**: Семейство моделей с открытыми весами, использующее архитектуру
38 transformer с Grouped-Query Attention (GQA) и токенизатором на 128 000 токенов.
39 - **Сильные стороны**: Огромное сообщество, обилие инженерных инструментов для локального
40 запуска и модификаций (vLLM, Hugging Face, TransformerLens). Отличная документация
41 архитектуры.
42 - **Слабые стороны**: Данные и код обучения не открыты. У меня нет информации о точных
43 пропорциях и составе обучающих данных Llama 3, так как разработчики предоставляют только
44 высокоуровневые описания (например, указание на наличие >5% высококачественного неанглийского
45 текста).
46 - **Ограничения**: Невозможность точно воспроизвести процесс обучения с нуля.
47 - **Возможные инженерные риски**: Лицензионные ограничения могут усложнить некоторые виды
48 модификаций или перелицензирования модифицированных версий.
49 - **Общая оценка**: Хороша для изучения архитектуры и модификации инференса, но не подходит
50 как полностью воспроизводимый стенд обучения.
51
52 #### **Mistral (Mistral AI)**
53 - **Краткое описание**: Модели с открытыми весами, известные эффективной архитектурой, включая
54 Sliding Window Attention, GQA и Rotary Position Embedding (RoPE).
55 - **Сильные стороны**: Высокая эффективность, хорошая документация архитектуры и механизмов
56 внимания.
57 - **Слабые стороны**: Закрытые данные обучения и код обучения. Токенизатор документирован, но
58 детали микса данных отсутствуют.
59 - **Ограничения**: Непригодна для полного воспроизведения процесса обучения.
60 - **Возможные инженерные риски**: Сдвиг компании в сторону проприетарных моделей может снизить
61 внимание к поддержке открытых исследовательских инструментов.
62 - **Общая оценка**: Подходит для экспериментов с архитектурой внимания, но не как полностью
63 прозрачный стенд.
64
65 #### **Qwen 2.5 (Alibaba)**
66 - **Краткое описание**: Семейство плотных decoder-only моделей с открытыми весами, обученных
67 на 18 триллионах токенов.
68 - **Сильные стороны**: Отличная техническая документация, открытые веса, хорошая поддержка
69 инструментов. Токенизатор (BPE) хорошо документирован.
```

```
40 - **Слабые стороны**: Данные обучения не открыты полностью. У меня нет информации о точном
41   составе и источниках этих 18 триллионов токенов.
42 - **Ограничения**: Воспроизводимость обучения невозможна.
43 - **Возможные инженерные риски**: Зависимость от будущей политики компании в области
44   открытости исходного кода.
45 - **Общая оценка**: Крепкий кандидат для экспериментов с инференсом и дообучением
46   (fine-tuning), но не для изучения процесса обучения с нуля.
47
48 ##### **Gemma 2 (Google)**
49 - **Краткое описание**: Легковесные открытые модели, использующие чередование локального и
50   глобального внимания и GQA.
51 - **Сильные стороны**: Хорошая техническая документация (technical report), открытые веса,
52   поддержка инструментов разработчика.
53 - **Слабые стороны**: Данные обучения не открыты.
54 - **Ограничения**: Неполная прозрачность по сравнению с OLMo или Pythia.
55 - **Возможные инженерные риски**: Ограничения лицензии могут усложнить некоторые виды
56   модификаций и коммерциализации результатов исследований.
57 - **Общая оценка**: Хороший объект для изучения архитектурных инноваций (например, logit
58   soft-capping), но не для полной воспроизводимости.
59
60 ##### **Falcon (TII)**
61 - **Краткое описание**: Модели с открытыми весами, использующие Multi-Query Attention и
62   FlashAttention.
63 - **Сильные стороны**: Открытые веса, хорошая документация архитектуры.
64 - **Слабые стороны**: Данные обучения (RefinedWeb) описаны высокоуровнево, код обучения не
65   полностью открыт для воспроизведения.
66 - **Ограничения**: Меньшая активность исследовательского сообщества по сравнению с Llama или
67   Qwen.
68 - **Возможные инженерные риски**: Снижение темпов развития проекта по сравнению с
69   конкурентами.
70 - **Общая оценка**: Устаревает как эталон по сравнению с OLMo/LLM360 по критерию полной
71   прозрачности.
72
73 ---
74
75 ### 2. Сравнительная таблица
76
77 | Модель | Открытость весов и архитектуры | Документация обучения и токенизатора |
78 | | | Возможность локальной модификации | Инструменты исследования (интерпретируемость) |
79 | | | Воспроизводимость обучения | Пригодность как стенд (1-10) |
80 | :-----: | :-----: | :-----: | :-----: |
81 | :-----: | :-----: | :-----: | :-----: |
82 | :-----: | :-----: | :-----: | :-----: |
83 | **OLMo** | Полная | Высокая | Полная (данные Dolma, код, логи) |
84 | | Высокая | **10** | Высокая |
85 | **Полная** | **10** | **Полная** | **9.5** |
86 | **LLM360 / Pythia** | Полная | Высокая | Полная (все чекпоинты, код) |
87 | | Высокая | **Очень высокая** | **9.5** |
88 | **Llama 3** | Весов: Да, Кода: Нет | Частичная (архитектура да, данные нет) |
89 | | Высокая | Высокая |
90 | Отсутствует | 7 |
91 | **Mistral** | Весов: Да, Кода: Нет | Частичная (архитектура да, данные нет) |
92 | | Высокая | Средняя |
93 | Отсутствует | 6.5 |
94 | **Qwen 2.5** | Весов: Да, Кода: Нет | Частичная (архитектура да, данные нет) |
95 | | Высокая | Средняя |
96 | Отсутствует | 7 |
97 | **Gemma 2** | Весов: Да, Кода: Нет | Частичная (архитектура да, данные нет) |
98 | | Высокая | Средняя |
99 | Отсутствует | 6.5 |
100 | **Falcon** | Весов: Да, Кода: Нет | Частичная | Низкая |
101 | | Средняя | Отсутствует | 5.5 |
102 | | | |
103
104 ---
105
106 ### 3. Итоговый анализ
```

78

79 ****1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?****

80 Наиболее подходящей моделью является ****OLMo**** (или проекты семейства ****LLM360****, такие как Amber/K2).

81

82 ****2. Почему именно она?****

83 Потому что это единственные модели, которые предоставляют полный доступ к обучающим данным (например, корпус Dolma), исходному коду обучения, логам и всем промежуточным чекпоинтам. Это является обязательным инженерным условием для "воспроизводимых экспериментов и последующих контролируемых модификаций", так как позволяет не только менять архитектуру, но и точно воспроизводить процесс обучения для проверки гипотез.

84

85 ****3. Какая модель занимает второе место?****

86 Второе место занимает ****Pythia**** от EleutherAI. Она была специально создана для изучения динамики обучения и интерпретируемости, предоставляя исследователям все чекпоинты с самого начала обучения, что критически важно для лабораторных экспериментов. Если же говорить о моделях из исходного списка, то второе место занимает ****Llama 3**** исключительно за счет огромного количества сторонних инженерных инструментов и документации по архитектуре, несмотря на закрытость данных.

87

88 ****4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?****

89 - ****Наличие промежуточных чекпоинтов****: Критически важно для изучения динамики обучения (learning dynamics), а не только финального состояния модели.

90 - ****Лицензионная чистота для модификаций****: Возможность свободного изменения кода и перелицензирования модифицированной версии без юридических барьеров (например, некоторые лицензии запрещают использование результатов для обучения других моделей).

91 - ****Нативная совместимость с фреймворками механистической интерпретируемости****: Например, готовность архитектуры к загрузке в `TransformerLens` или `nnsight` без необходимости написания сложных кастомных слоев.

92

93 ****5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в качестве долгосрочного экспериментального стенда?****

94 - ****Дрейф зависимостей****: Библиотеки (PyTorch, Transformers) обновляются, и код обучения или скрипты модификации, написанные сегодня, могут перестать работать через год, требуя постоянной поддержки.

95 - ****Аппаратные ограничения****: Полное воспроизведение обучения даже для 7B-моделей требует значительных вычислительных кластеров. Для локальных экспериментов придется ограничиваться микро-моделями или использовать методы вроде LoRA, что сужает класс возможных экспериментов.

96 - ****Неопределенность данных****: У меня нет информации о точном составе обучающих данных для моделей вроде Llama 3 или Qwen 2.5, так как разработчики предоставляют только высокоуровневые описания. Это делает невозможным строгое воспроизведение их обучения, что является фундаментальным ограничением для некоторых типов экспериментов.