

1 EXP-001. Выбор эталонной открытой LLM для экспериментального стенда
2 Краткий разбор кандидатов
3 Llama (Meta)
4 ОписаниеСемейство моделей от Meta (Llama 2, 3, 4). Веса доступны, но с ограничениями по
лицензии (Llama Community License). Архитектура – классический трансформер с некоторыми
оптимизациями (GQA, RoPE и т.д.).
5 Сильные стороны
6
7 Веса доступны для локального запуска и экспериментов.
8 Огромное сообщество: множество форков, адаптаций, инструментов (llama.cpp, vLLM, Hugging
Face).
9 Хорошо документированы API и практические руководства по развёртыванию.
10 Относительно простой трансформерный дизайн (не MoE), что упрощает модификацию.
11
12 Слабые стороны
13
14 Не полностью открытый стек: данные обучения и многие детали процесса скрыты.
15 Лицензия не Apache 2.0 / MIT, есть ограничения на крупных игроков и географию (особенно для
мультимодальных версий).
16 Документация архитектуры и обучения скорее «обзорная», чем детальная.
17 Токенизатор и механизм внимания описаны на уровне общей схемы, но не до уровня полной
воспроизводимости.
18
19 Ограничения
20
21 Нельзя полностью воспроизвести обучение с нуля по документации.
22 Нет полного набора инструментов для исследования внутренних механизмов «из коробки».
23
24 Инженерные риски
25
26 Зависимость от Meta в плане лицензии и будущих изменений.
27 Неполная прозрачность данных обучения может затруднить анализ поведения модели в узких
доменах.
28
29 Общая оценкаХороший кандидат для практических экспериментов и локального запуска, но не
идеальный стенд из-за недостаточной прозрачности стека и лицензионных нюансов.
30
31 OLMo (Allen Institute for AI)
32 ОписаниеOLMo – семейство полностью открытых языковых моделей от некоммерческого Allen
Institute for AI. Архитектура – трансформер, обучение на открытых данных Dolma, код, данные и
веса доступны под Apache 2.0.
33 Сильные стороны
34
35 Полная открытость: веса, код обучения, данные, конфигурации, логи.
36 Подробная техническая документация и научные статьи, описывающие архитектуру, токенизатор,
механизм внимания, гиперпараметры.
37 Токенизатор и механизм внимания документированы на уровне, достаточном для воспроизведения.
38 Локальный запуск и модификация компонентов поддерживаются официальными репозиториями.
39 Есть инструменты для исследования внутренних механизмов (например, OLMoTrace для трассировки
выходов к данным обучения).
40 Воспроизводимость результатов высокая: можно повторить обучение с нуля.
41 Активное исследовательское сообщество вокруг Ai2 и академических институтов.
42 Долговременная поддержка как со стороны Ai2, так и сообщества.
43
44 Слабые стороны
45
46 Модели относительно небольшие по сравнению с Llama 3.3/4 или Mistral Large (например,
OLMo-3-32B против Llama 3.3 70B).
47 Меньше готовых прикладных инструментов «под ключ» по сравнению с Llama или Mistral.
48
49 Ограничения
50
51 Если нужны очень большие модели (сотни миллиардов параметров), OLMo пока уступает
Llama/Mistral.
52
53 Инженерные риски
54
55 Риски минимальны: Apache 2.0, некоммерческий разработчик, прозрачный стек.
56

57 Общая оценкаНаиболее подходящая модель в качестве эталонной инженерной платформы из-за полной
прозрачности, воспроизводимости и исследовательской направленности.

58

59 Mistral

60 ОписаниеMistral AI выпускает как открытые модели (Mistral 7B, Mixtral 8x7B, Mistral NeMo 12B
под Apache 2.0), так и коммерческие (Mistral Large). Архитектура – трансформер, часто с
Mixture-of-Experts (MoE).

61 Сильные стороны

62

63 Некоторые модели полностью открыты под Apache 2.0 (например, Mistral NeMo 12B).
64 Хорошая документация по API и развёртыванию.
65 Поддержка в популярных фреймворках (Hugging Face, vLLM, mistral.rs).
66 MoE-архитектура интересна для исследования эффективности и специализации экспертов.

67

68 Слабые стороны

69

70 Не все модели полностью открыты: часть доступна только через API или с ограничениями.
71 Данные обучения и детали процесса часто не раскрываются.
72 Документация архитектуры и механизмов внимания скорее обзорная.
73 Для MoE-моделей модификация компонентов сложнее из-за распределённой природы экспертов.

74

75 Ограничения

76

77 Воспроизведение обучения с нуля затруднено из-за недостатка данных и деталей.

78

79 Инженерные риски

80

81 Зависимость от коммерческой компании; стратегия открытости может меняться.
82 MoE усложняет эксперименты с заменой или отключением отдельных механизмов.

83

84 Общая оценкаХороший выбор для практических приложений и некоторых исследований, но не лучший
стенд из-за неполной прозрачности стека.

85

86 Qwen (Alibaba Cloud)

87 ОписаниеСемейство моделей от Alibaba Cloud. Многие версии открыты под Apache 2.0 или близкими
лицензиями. Архитектура – трансформер, часто с гибридным MoE и линейным вниманием.

88 Сильные стороны

89

90 Активное сообщество и множество инструментов (Qwen-Agent, ModelScope).
91 Хорошая документация по использованию и развёртыванию.
92 Поддержка мультимодальности и агентских возможностей.
93 Некоторые модели полностью открыты под Apache 2.0.

94

95 Слабые стороны

96

97 Не все модели одинаково открыты: есть проприетарные версии и лицензионные ограничения.
98 Данные обучения и детали процесса часто не раскрываются полностью.
99 Архитектура усложнена (гибридный MoE, линейное внимание), что затрудняет модификацию.
100 Документация архитектуры и механизмов внимания скорее обзорная.

101

102 Ограничения

103

104 Воспроизведение обучения с нуля затруднено.
105 Часть инструментов завязана на экосистему Alibaba.

106

107 Инженерные риски

108

109 Зависимость от китайской компании и её политики открытости.
110 Сложная архитектура увеличивает порог входа для глубоких модификаций.

111

112 Общая оценкаМощная и гибкая модель для приложений, но не идеальный стенд из-за неполной
прозрачности и сложности архитектуры.

113

114 Gemma (Google DeepMind)

115 ОписаниеСемейство лёгких открытых моделей от Google DeepMind, основанных на технологии Gemini.
Веса доступны, лицензия позволяет коммерческое использование.

116 Сильные стороны

117

118 Веса открыты, есть официальные библиотеки (gemma PyPI) и документация.

119 Хорошая интеграция с популярными фреймворками (JAX, PyTorch, TensorFlow, Hugging Face).
120 Активное сообщество и множество руководств по тонкой настройке.
121 Относительно простой трансформерный дизайн (для базовых версий).
122
123 Слабые стороны
124
125 Данные обучения и многие детали процесса скрыты.
126 Документация архитектуры и механизмов внимания скорее обзорная.
127 Неполная прозрачность стека обучения.
128 Нет инструментов для глубокого исследования внутренних механизмов «из коробки».
129
130 Ограничения
131
132 Воспроизведение обучения с нуля затруднено.
133 Модели ориентированы на лёгкость и эффективность, а не на максимальную прозрачность.
134
135 Инженерные риски
136
137 Зависимость от Google и его политики открытости.
138 Риск изменения лицензионных условий в будущем.
139
140 Общая оценкаХороший выбор для прикладных экспериментов и лёгких моделей, но не лучший стенд из-за недостаточной прозрачности стека.
141
142 Falcon (Technology Innovation Institute)
143 ОписаниеСемейство моделей от Technology Innovation Institute (ОАЭ). Веса доступны под Apache 2.0, архитектура – трансформер с некоторыми оптимизациями.
144 Сильные стороны
145
146 Веса открыты под Apache 2.0.
147 Относительно простая трансформерная архитектура.
148 Поддержка в Hugging Face и других фреймворках.
149
150 Слабые стороны
151
152 Активность проекта и сообщества ниже, чем у Llama, Mistral или Qwen.
153 Документация архитектуры и обучения менее детальна.
154 Данные обучения и многие детали процесса скрыты.
155 Меньше инструментов для исследования внутренних механизмов.
156
157 Ограничения
158
159 Воспроизведение обучения с нуля затруднено.
160 Долговременная поддержка менее предсказуема.
161
162 Инженерные риски
163
164 Зависимость от одного института; активность проекта может снизиться.
165
166 Общая оценкаИнтересный кандидат с точки зрения лицензии, но не лучший стенд из-за меньшей прозрачности и активности сообщества.
167
168 Сравнительная таблица
169 Оценка по шкале:
170
171 ☒ – хорошо / полностью удовлетворяет критерию
172 ☐ – частично / с оговорками
173 ☐ – плохо / не удовлетворяет критерию
174
175
176
177
178 Критерий
179 Llama
180 OLMo
181 Mistral
182 Qwen
183 Gemma
184 Falcon

185	
186	
187	
188	Открытость архитектуры
189	
190	
191	
192	
193	
194	
195	
196	
197	Доступность весов
198	
199	
200	
201	
202	
203	
204	
205	
206	Полнота техдокументации
207	
208	
209	
210	
211	
212	
213	
214	
215	Документированность процесса обучения
216	
217	
218	
219	
220	
221	
222	
223	
224	Документированность токенизатора
225	
226	
227	
228	
229	
230	
231	
232	
233	Документированность механизма внимания
234	
235	
236	
237	
238	
239	
240	
241	
242	Возможность локального запуска
243	
244	
245	
246	
247	
248	
249	
250	
251	Возможность локальной модификации компонентов
252	
253	

254	☒
255	☐
256	☒
257	☒
258	
259	
260	Возможность отключения/замены механизмов
261	☒
262	☒
263	☐
264	☐
265	☒
266	☒
267	
268	
269	Инженерные инструменты исследования
270	☐
271	☒
272	☐
273	☐
274	☐
275	☐
276	
277	
278	Воспроизводимость результатов
279	☒
280	☒
281	☒
282	☒
283	☒
284	☒
285	
286	
287	Размер и активность сообщества
288	☒
289	☐
290	☒
291	☒
292	☒
293	☐
294	
295	
296	Долговременная поддержка
297	☒
298	☒
299	☐
300	☐
301	☒
302	☐
303	
304	
305	Пригодность как экспериментальный стенд
306	☐
307	☒
308	☐
309	☐
310	☐
311	☐
312	
313	
314	
315	Итоговый анализ
316	1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?
317	OLMo (Allen Institute for AI).
318	2. Почему именно она?
319	
320	Полная прозрачность стека: веса, код обучения, данные, конфигурации, логи – всё открыто под Apache 2.0.
321	Детальная документация: архитектура, токенизатор, механизм внимания, гиперпараметры описаны на

уровне, достаточном для воспроизведения.

322 Воспроизводимость: можно повторить обучение с нуля, проводить контролируемые эксперименты и абляции.

323 Инженерные инструменты: например, OLMoTrace для трассировки выходов к данным обучения.

324 Некоммерческий разработчик: меньше рисков изменения политики открытости.

325 Исследовательская направленность: модель изначально заточена под прозрачность и исследования, а не под коммерческий успех.

326

327 3. Какая модель занимает второе место?

328 Llama (Meta).

329 Причины:

330

331 Огромное сообщество и множество инструментов для локального запуска и модификации.

332 Относительно простая трансформерная архитектура.

333 Веса доступны для большинства сценариев.

334

335 Но она уступает OLMo по прозрачности стека обучения и лицензионной чистоте.

336 4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?

337

338 Сложность архитектуры: например, наличие MoE, гибридных механизмов внимания, которые усложняют модификацию и анализ.

339 Инфраструктурные требования: объём памяти, необходимость многопроцессорных систем, поддержка квантования.

340 Скорость итерации: насколько быстро можно переобучить модель или провести серию экспериментов.

341 Интеграция с инструментами анализа: поддержка профилирования, визуализации внимания, интерпретируемости.

342 Стабильность API и форматов: насколько часто меняются конфигурации, форматы чекпоинтов, что может сломать долгосрочные эксперименты.

343

344 5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в качестве долгосрочного экспериментального стенда?

345

346 Масштабируемость: OLMo – не самые большие модели; если понадобятся сотни миллиардов параметров, придётся либо масштабировать инфраструктуру, либо переходить на другую модель.

347 Скорость развития: новые версии OLMo могут менять архитектуру или форматы данных, что потребует миграции экспериментов.

348 Инструменты: часть исследовательских инструментов (например, OLMoTrace) может требовать доработки под конкретные задачи.

349 Сообщество: хотя оно активно, оно меньше, чем у Llama или Mistral, поэтому некоторые нишевые проблемы могут решаться медленнее.

350 Данные обучения: несмотря на открытость, объём данных огромен; их обработка и анализ требуют серьёзных вычислительных ресурсов. EXP-001. Выбор эталонной открытой LLM для экспериментального стенда

351 Краткий разбор кандидатов

352 Llama (Meta)

353 Описание Семейство моделей от Meta (Llama 2, 3, 4). Веса доступны, но с ограничениями по лицензии (Llama Community License). Архитектура – классический трансформер с некоторыми оптимизациями (GQA, RoPE и т.д.).

354 Сильные стороны

355

356 Веса доступны для локального запуска и экспериментов.

357 Огромное сообщество: множество форков, адаптаций, инструментов (llama.cpp, vLLM, Hugging Face).

358 Хорошо документированы API и практические руководства по развёртыванию.

359 Относительно простой трансформерный дизайн (не MoE), что упрощает модификацию.

360

361 Слабые стороны

362

363 Не полностью открытый стек: данные обучения и многие детали процесса скрыты.

364 Лицензия не Apache 2.0 / MIT, есть ограничения на крупных игроков и географию (особенно для мультимодальных версий).

365 Документация архитектуры и обучения скорее «обзорная», чем детальная.

366 Токенизатор и механизм внимания описаны на уровне общей схемы, но не до уровня полной воспроизводимости.

367

368 Ограничения

369

370 Нельзя полностью воспроизвести обучение с нуля по документации.

371 Нет полного набора инструментов для исследования внутренних механизмов «из коробки».

372
373 Инженерные риски
374
375 Зависимость от Meta в плане лицензии и будущих изменений.
376 Неполная прозрачность данных обучения может затруднить анализ поведения модели в узких
доменах.
377
378 Общая оценкаХороший кандидат для практических экспериментов и локального запуска, но не
идеальный стек из-за недостаточной прозрачности стека и лицензионных нюансов.
379
380 OLMo (Allen Institute for AI)
381 ОписаниеOLMo – семейство полностью открытых языковых моделей от некоммерческого Allen
Institute for AI. Архитектура – трансформер, обучение на открытых данных Dolma, код, данные и
веса доступны под Apache 2.0.
382 Сильные стороны
383
384 Полная открытость: веса, код обучения, данные, конфигурации, логи.
385 Подробная техническая документация и научные статьи, описывающие архитектуру, токенизатор,
механизм внимания, гиперпараметры.
386 Токенизатор и механизм внимания документированы на уровне, достаточном для воспроизведения.
387 Локальный запуск и модификация компонентов поддерживаются официальными репозиториями.
388 Есть инструменты для исследования внутренних механизмов (например, OLMoTrace для трассировки
выходов к данным обучения).
389 Воспроизводимость результатов высокая: можно повторить обучение с нуля.
390 Активное исследовательское сообщество вокруг Ai2 и академических институтов.
391 Долговременная поддержка как со стороны Ai2, так и сообщества.
392
393 Слабые стороны
394
395 Модели относительно небольшие по сравнению с Llama 3.3/4 или Mistral Large (например,
OLMo-3-32B против Llama 3.3 70B).
396 Меньше готовых прикладных инструментов «под ключ» по сравнению с Llama или Mistral.
397
398 Ограничения
399
400 Если нужны очень большие модели (сотни миллиардов параметров), OLMo пока уступает
Llama/Mistral.
401
402 Инженерные риски
403
404 Риски минимальны: Apache 2.0, некоммерческий разработчик, прозрачный стек.
405
406 Общая оценкаНаиболее подходящая модель в качестве эталонной инженерной платформы из-за полной
прозрачности, воспроизводимости и исследовательской направленности.
407
408 Mistral
409 ОписаниеMistral AI выпускает как открытые модели (Mistral 7B, Mixtral 8x7B, Mistral NeMo 12B
под Apache 2.0), так и коммерческие (Mistral Large). Архитектура – трансформер, часто с
Mixture-of-Experts (MoE).
410 Сильные стороны
411
412 Некоторые модели полностью открыты под Apache 2.0 (например, Mistral NeMo 12B).
413 Хорошая документация по API и развёртыванию.
414 Поддержка в популярных фреймворках (Hugging Face, vLLM, mistral.rs).
415 MoE-архитектура интересна для исследования эффективности и специализации экспертов.
416
417 Слабые стороны
418
419 Не все модели полностью открыты: часть доступна только через API или с ограничениями.
420 Данные обучения и детали процесса часто не раскрываются.
421 Документация архитектуры и механизмов внимания скорее обзорная.
422 Для MoE-моделей модификация компонентов сложнее из-за распределённой природы экспертов.
423
424 Ограничения
425
426 Воспроизведение обучения с нуля затруднено из-за недостатка данных и деталей.
427
428 Инженерные риски
429

430 Зависимость от коммерческой компании; стратегия открытости может меняться.
431 МоЕ усложняет эксперименты с заменой или отключением отдельных механизмов.
432

433 Общая оценкаХороший выбор для практических приложений и некоторых исследований, но не лучший
стенд из-за неполной прозрачности стека.

434

435 Qwen (Alibaba Cloud)

436 ОписаниеСемейство моделей от Alibaba Cloud. Многие версии открыты под Apache 2.0 или близкими
лицензиями. Архитектура – трансформер, часто с гибридным МоЕ и линейным вниманием.

437 Сильные стороны

438

439 Активное сообщество и множество инструментов (Qwen-Agent, ModelScope).
440 Хорошая документация по использованию и развёртыванию.
441 Поддержка мультимодальности и агентских возможностей.
442 Некоторые модели полностью открыты под Apache 2.0.

443

444 Слабые стороны

445

446 Не все модели одинаково открыты: есть проприетарные версии и лицензионные ограничения.
447 Данные обучения и детали процесса часто не раскрываются полностью.
448 Архитектура усложнена (гибридный МоЕ, линейное внимание), что затрудняет модификацию.
449 Документация архитектуры и механизмов внимания скорее обзорная.

450

451 Ограничения

452

453 Воспроизведение обучения с нуля затруднено.
454 Часть инструментов завязана на экосистему Alibaba.

455

456 Инженерные риски

457

458 Зависимость от китайской компании и её политики открытости.
459 Сложная архитектура увеличивает порог входа для глубоких модификаций.

460

461 Общая оценкаМощная и гибкая модель для приложений, но не идеальный стенд из-за неполной
прозрачности и сложности архитектуры.

462

463 Gemma (Google DeepMind)

464 ОписаниеСемейство лёгких открытых моделей от Google DeepMind, основанных на технологии Gemini.
Веса доступны, лицензия позволяет коммерческое использование.

465 Сильные стороны

466

467 Веса открыты, есть официальные библиотеки (gemma PyPI) и документация.
468 Хорошая интеграция с популярными фреймворками (JAX, PyTorch, TensorFlow, Hugging Face).
469 Активное сообщество и множество руководств по тонкой настройке.
470 Относительно простой трансформерный дизайн (для базовых версий).

471

472 Слабые стороны

473

474 Данные обучения и многие детали процесса скрыты.
475 Документация архитектуры и механизмов внимания скорее обзорная.
476 Неполная прозрачность стека обучения.
477 Нет инструментов для глубокого исследования внутренних механизмов «из коробки».

478

479 Ограничения

480

481 Воспроизведение обучения с нуля затруднено.
482 Модели ориентированы на лёгкость и эффективность, а не на максимальную прозрачность.

483

484 Инженерные риски

485

486 Зависимость от Google и его политики открытости.
487 Риск изменения лицензионных условий в будущем.

488

489 Общая оценкаХороший выбор для прикладных экспериментов и лёгких моделей, но не лучший стенд
из-за недостаточной прозрачности стека.

490

491 Falcon (Technology Innovation Institute)

492 ОписаниеСемейство моделей от Technology Innovation Institute (ОАЭ). Веса доступны под Apache
2.0, архитектура – трансформер с некоторыми оптимизациями.

493	Сильные стороны						
494							
495	Веса открыты под Apache 2.0.						
496	Относительно простая трансформерная архитектура.						
497	Поддержка в Hugging Face и других фреймворках.						
498							
499	Слабые стороны						
500							
501	Активность проекта и сообщества ниже, чем у Llama, Mistral или Qwen.						
502	Документация архитектуры и обучения менее детальна.						
503	Данные обучения и многие детали процесса скрыты.						
504	Меньше инструментов для исследования внутренних механизмов.						
505							
506	Ограничения						
507							
508	Воспроизведение обучения с нуля затруднено.						
509	Долговременная поддержка менее предсказуема.						
510							
511	Инженерные риски						
512							
513	Зависимость от одного института; активность проекта может снизиться.						
514							
515	Общая оценкаИнтересный кандидат с точки зрения лицензии, но не лучший стенд из-за меньшей прозрачности и активности сообщества.						
516							
517	Сравнительная таблица						
518	Оценка по шкале:						
519							
520	☑ – хорошо / полностью удовлетворяет критерию						
521	⚠ – частично / с оговорками						
522	✖ – плохо / не удовлетворяет критерию						
523							
524	Критерий	Llama	OLMo	Mistral	Qwen	Gemma	Falcon
525							
526	Открытость архитектуры	⚠	☑	⚠	⚠	⚠	⚠
527							
528	Доступность весов	☑	☑	☑	☑	☑	☑
529							
530	Полнота техдокументации	⚠	☑	⚠	⚠	⚠	⚠
531							
532	Документированность процесса обучения	✖	☑	✖	✖	✖	✖
533							
534	Документированность токенизатора	⚠	☑	⚠	⚠	⚠	⚠
535							
536	Документированность механизма внимания	⚠	☑	⚠	⚠	⚠	⚠
537							
538	Возможность локального запуска	☑	☑	☑	☑	☑	☑
539							
540	Возможность локал. модификации комп-тов	☑	☑	☑	⚠	☑	☑
541							
542	Возможность отключ./замены механизмов	☑	☑	⚠	⚠	☑	☑
543							
544	Инженерные инструменты исследования	⚠	☑	⚠	⚠	⚠	⚠
545							
546	Воспроизводимость результатов	✖	☑	✖	✖	✖	✖
547							
548	Размер и активность сообщества	☑	⚠	☑	☑	☑	⚠
549							
550	Долговременная поддержка	☑	☑	⚠	⚠	☑	⚠
551							
552	Пригодность как экспериментальный стенд	⚠	☑	⚠	⚠	⚠	⚠
553							
554							
555							
556	Итоговый анализ						
557	1. Какая модель наиболее подходит в качестве эталонной инженерной платформы?						
558	OLMo (Allen Institute for AI).						
559	2. Почему именно она?						
560							

561 Полная прозрачность стека: веса, код обучения, данные, конфигурации, логи – всё открыто под Apache 2.0.

562 Детальная документация: архитектура, токенизатор, механизм внимания, гиперпараметры описаны на уровне, достаточном для воспроизведения.

563 Воспроизводимость: можно повторить обучение с нуля, проводить контролируемые эксперименты и абляции.

564 Инженерные инструменты: например, OLMoTrace для трассировки выходов к данным обучения.

565 Некоммерческий разработчик: меньше рисков изменения политики открытости.

566 Исследовательская направленность: модель изначально заточена под прозрачность и исследования, а не под коммерческий успех.

567

568 3. Какая модель занимает второе место?

569 Llama (Meta).

570 Причины:

571

572 Огромное сообщество и множество инструментов для локального запуска и модификации.

573 Относительно простая трансформерная архитектура.

574 Веса доступны для большинства сценариев.

575

576 Но она уступает OLMo по прозрачности стека обучения и лицензионной чистоте.

577 4. Какие критерии выбора, по вашему мнению, отсутствуют в данном исследовании?

578

579 Сложность архитектуры: например, наличие MoE, гибридных механизмов внимания, которые усложняют модификацию и анализ.

580 Инфраструктурные требования: объём памяти, необходимость многопроцессорных систем, поддержка квантования.

581 Скорость итерации: насколько быстро можно переобучить модель или провести серию экспериментов.

582 Интеграция с инструментами анализа: поддержка профилирования, визуализации внимания, интерпретируемости.

583 Стабильность API и форматов: насколько часто меняются конфигурации, форматы чекпоинтов, что может сломать долгосрочные эксперименты.

584

585 5. Какие потенциальные проблемы могут возникнуть при использовании выбранной модели в качестве долгосрочного экспериментального стенда?

586

587 Масштабируемость: OLMo – не самые большие модели; если понадобятся сотни миллиардов параметров, придётся либо масштабировать инфраструктуру, либо переходить на другую модель.

588 Скорость развития: новые версии OLMo могут менять архитектуру или форматы данных, что потребует миграции экспериментов.

589 Инструменты: часть исследовательских инструментов (например, OLMoTrace) может требовать доработки под конкретные задачи.

590 Сообщество: хотя оно активно, оно меньше, чем у Llama или Mistral, поэтому некоторые нишевые проблемы могут решаться медленнее.

591 Данные обучения: несмотря на открытость, объём данных огромен; их обработка и анализ требуют серьёзных вычислительных ресурсов.